

Documento Metodológico

Departamento de Riesgos

Modelo Comportamental PP Foco Reenganche

Author: Jesus Z.

ver- sion	Respons- able	Descripción del cambio	Fecha
2	Jesus Z.	Exclusión de variables SuSalud (privacidad de datos) y reentrenamiento sobre dataset pro- ductivo. Variables finales: 54 → 48.	Julio 2026

1. Introducción

Los modelos comportamentales estiman la probabilidad de incumplimiento (probability of default, PD) de clientes con productos vigentes, a partir de su experiencia crediticia histórica. Su salida se emplea como insumo en las decisiones de gestión de cartera y, en particular, como criterio de elegibilidad y ordenamiento (ranking) de riesgo en procesos de originación sobre clientes existentes.

El presente documento describe la metodología de desarrollo del Modelo Comportamental de Préstamos Personales (PP) – Foco Reenganche. Este modelo constituye un reentrenamiento del modelo comportamental PP vigente, conservando su población objetivo (PO), su definición de variable objetivo y su diseño metodológico. Las modificaciones respecto del modelo vigente son: (i) la actualización de las ventanas de desarrollo hacia periodos más recientes, y (ii) la incorporación de nuevas variables explicativas más afines al perfil de reenganche, incluyendo variables provenientes de fuentes del grupo InterCorp. Adicionalmente, en esta segunda versión del modelo se excluyeron las variables provenientes de la fuente SuSalud, en cumplimiento de los lineamientos de privacidad de datos personales. Asimismo, durante la evaluación de consistencia entre el entorno de desarrollo y el entorno productivo, se identificó que el porcentaje de coincidencia de variables entre ambas versiones no alcanzaba un nivel significativo, lo cual constituyó un motivo adicional para reentrenar el modelo utilizando el dataset de la versión productiva, garantizando así la trazabilidad y consistencia entre el insumo de desarrollo y el de implementación. Como consecuencia de dicha exclusión y del reentrenamiento sobre la base productiva, se reejecutó el proceso de selección de variables y los análisis asociados; en esta reestimación, cuatro variables adicionales evidenciaron una pérdida de relevancia en términos de importancia SHAP relativa, por lo que fueron igualmente descartadas. De este modo, el conjunto final de variables explicativas se redujo de 54, en la primera versión, a 48 en la versión actual, sin que ello comprometa el desempeño ni la estabilidad del modelo.

Objetivo del modelo. Estimar la probabilidad de que un cliente con préstamo personal activo incurra en default —definido como atraso mayor a 60 días— dentro de un horizonte de desempeño de 12 meses. (ver §2.5.)

Objetivo de negocio (uso previsto). La estimación de PD habilita la identificación de clientes elegibles para campañas de reenganche (incremento de saldo sobre clientes con PP activo), de modo que el crecimiento del portafolio se realice dentro del apetito de riesgo definido por el Banco. El modelo no optimiza objetivos comerciales; provee una medida de riesgo que el negocio utiliza como filtro y criterio de priorización.

Metodológicamente, se trata de un modelo de clasificación binaria desarrollado con técnicas de Machine Learning (ver §4). La unidad de observación es el cliente con al menos un PP activo en cada fecha de corte. El desarrollo emplea información de clientes de productos de consumo (PP) que cumplen los filtros definidos en §2.2, sobre ventanas de observación y desempeño detalladas en §2.3.

1.1 Ambito de aplicación

Atributo	Definición
Tipología de Riesgo	Comportamiento (behavioral)
Producto	Préstamos Personales (PP)
Segmento / población	Clientes con al menos un Préstamo Personal activo (stock)
Tipo de decisión	Originación sobre clientes existentes (reenganche)

1.2 Periodo de aplicación

Por tratarse de un reentrenamiento de un modelo comportamental, la vigencia se establece desde su implementación productiva, prevista para agosto de 2026, hasta la siguiente revisión periódica programada. Previo a la puesta en producción se ejecutará una evaluación de impacto operativo mediante piloto y/o reprocesamiento histórico del score sobre el stock vigente. El modelo quedará sujeto al monitoreo periódico de estabilidad.

1.3 Resumen del modelo

Característica	Detalle
Tipo de modelo	Clasificación binaria – PD comportamental
Algoritmo	CatBoost
N.º de modelos / segmentos	Único modelo, sin segmentación
Variable objetivo	Default: atraso > 60 días en horizonte de 12 meses
N.º de variables finales	48
Población objetivo	Clientes con PP activo que cumplen filtros
Relación con modelo previo	Reentrenamiento del modelo comportamental PP vigente

1.4 Uso del modelo en la gestión

El score se integra en la estrategia de campañas de reenganche como criterio de elegibilidad y de priorización por riesgo, identificando a los clientes con menor PD elegibles para incremento de saldo. La decisión final de campaña incorpora, además del score, las reglas de negocio y los límites de apetito de riesgo vigentes. El modelo provee ordenamiento de riesgo; no ejecuta de forma autónoma la aprobación.

2. Diseño del modelo

2.1 Obtención de la base inicial

Se ha extraído de las siguientes Bases de datos la información para el desarrollo del modelo.

- Bases de Stock de Préstamos.
- Bases de Cierre Mensual.
- Bases de Riesgo Crediticio Consolidado Sistema Financiero (RCC)
- Base de Productos por Cliente
- Bases de Transacciones por Canal
- Bases Sociodemográficas

Para la base inicial de construcción;

- Se consideraron los meses desde enero 2024 hasta diciembre 2024 para el desarrollo y para validación los meses de enero a marzo 2025

Para todo este periodo se dispone de información de cada una de las operaciones correspondientes a préstamos personales disponibles en las Bases de Stock de préstamos del periodo 2024 y 2025.

El universo de operaciones consideradas son las que se encuentran vigentes en la fecha de referencia y con menos de 8 días de mora.

Sobre esta muestra del stock de préstamos se realizó un cruce con las Bases de Cierre Mensual para construir el indicador de incumplimiento y una tabla proporcionada por el

equipo de riesgos para determinar qué operaciones caían en tramos refinanciados o de castigo.

Las operaciones con impago por más de 8 días pero que no llegan a ser malas a más de 60 días y que no sean malos por ser refinanciados o castigados, fueron marcadas para determinar las operaciones indeterminadas. Además, aquellas operaciones con impago menor a 8 días pero que tuvieron un desarrollo menor a los 3 meses consecutivos (más de 9 meses con missings) fueron marcadas para determinar las operaciones con un comportamiento bueno pero insuficiente. Por último, las operaciones que, si bien figuran en el stock de préstamos, no tienen comportamiento desde la fecha de referencia, fueron marcadas para determinar las operaciones vigentes, pero sin desarrollo. Más adelante se explican los filtros utilizados.

2.2 Filtros

Se eliminan aquellas operaciones que verifican alguna de las siguientes condiciones:

- **Garantía Hipotecaria:**

Motivo: Son operaciones que no son parte de nuestro universo objetivo, ya que pertenecen a un producto diferente al regular.

- **Colaboradores:**

Motivo: Son clientes que son colaboradores y que no forman parte de nuestro universo objetivo.

- **Malos en el SSFF:**

Motivo: Son clientes que tienen saldos en riesgo directo con más de 60 días de atraso a nivel SSFF en la fecha de referencia.

- **Malos en el origen:**

Motivo: Son clientes que poseen al menos un préstamo personal con atraso mayor a 60 días en la fecha de referencia, clientes con la marca de refinanciados y castigados en el mes de referencia.

- **Monto pendiente cero (0):**

Motivo: Son operaciones que se encuentran reportadas con monto pendiente de pago igual a cero (0) en la fecha de referencia.

- **Dado de baja:**

Motivo: Son operaciones que fueron dadas de baja en la fecha de referencia.

- **Bueno con historia insuficiente:**

Motivo: Son operaciones que cumplen con mantener hasta máximo 8 días de impago, pero que tuvieron un desarrollo menor a los 3 meses consecutivos de historia (más de 9 meses con missings), por lo que no se puede determinar que dichas operaciones sean buenas por no haber evidencia suficiente.

- **Indeterminado:**

Motivo: Son operaciones que no podemos determinar cómo buenas o malas, debido a que superan los 8 días de impago, con una tasa de recuperación menor al 50%, pero sin ser mayor a 60 días (no se filtran a los que son malos por ser refinanciados o castigados).

- **Inconsistencia RCC:**

Motivo: Son clientes que no figuran en el RCC aun teniendo desempeño en las Bases de Cierre Mensual.

Se presentan los filtros en el orden secuencial en que se aplican. El conteo "Restante" indica la base remanente tras cada exclusión; "Filtrados", el número de operaciones excluidas en ese paso.

Exclusión / Filtro	Restante	Filtrados
Base Inicial Stock PP	2'163'574	
Garantía Hipotecaria	2'160'877	2'697
Colaborador	2'160'108	769
Malo en el SSFF	2'002'453	157'655
Malo en el Origen	1'985'456	16'997
Monto Pendiente 0	1'985'401	55
Indeterminado	1'833'838	151'563
Bueno con historia insuf.	1'614'859	218'979
Base final de desarrollo	1'614'859	

2.3 Periodo de modelamiento

El desarrollo del Modelo Comportamental PP - Foco Reenganche se realizó utilizando información correspondiente a **12 periodos mensuales consecutivos**, comprendidos entre **enero 2024 (202401) y diciembre 2024 (202412)** mientras que los periodos para el OOT son los 3 primeros periodos de 2025 de enero a marzo 2025. Este rango temporal permite capturar el comportamiento reciente de la población objetivo bajo diferentes condiciones estacionales y coyunturales, asegurando una base representativa y robusta para el entrenamiento y validación del modelo predictivo.

2.4 Muestreo

Para llevar a cabo el muestreo de nuestra base de datos inicial que abarca desde enero de 2024 hasta marzo de 2025, hemos implementado un enfoque estratégico con el objetivo de construir dos grupos exclusivos, denominados Grupo 1 y Grupo 2, que permitan realizar un análisis de manera efectiva.

Paso 1: Muestreo del 50% de Clientes Únicos

En primera instancia, seleccionamos aleatoriamente el 50% de los clientes únicos en nuestros meses de entrenamiento y fuera de tiempo. Estos clientes conforman el Grupo 1.

Paso 2: Formación del Grupo 2

El Grupo 2 se compone de todos los clientes únicos que no fueron seleccionados para el Grupo 1. Esta selección garantiza que ambos grupos sean mutuamente excluyentes.

Paso 3: Muestreo de clientes para train, test y oot

Dentro del Grupo 1, identificamos a los clientes cuyos registros abarcan los meses desde enero de 2024 hasta diciembre de 2024. Estos clientes conformaran el conjunto de datos de entrenamiento (entrenamiento) que a la vez se particionarán en train y test con el método Split, tomando 30% para test y el complemento para train. Por otro lado, los clientes con registros en los meses de enero a marzo de 2025 y que provienen del grupo 2 pasaran a formar parte del conjunto de datos de prueba (out-of-time, OOT).

Este enfoque asegura que no haya duplicación de clientes entre los conjuntos de entrenamiento y prueba, lo que facilita un análisis preciso y representativo.

Este proceso de muestreo estratégico nos permite garantizar que los clientes en los conjuntos de entrenamiento y prueba sean únicos y no compartan datos entre sí. Además, al seleccionar aleatoriamente el 50% de los clientes para el Grupo 1, buscamos representar de manera efectiva la diversidad de nuestra base de datos en ambos grupos, lo que contribuirá a la calidad y validez de nuestro análisis posterior.

Muestra	Total
Train	461'803
Test	197'664
OOT	148'156

2.5 Target

El indicador bueno-malo se define a nivel cliente sobre una ventana de desempeño de 12 meses posterior a la fecha de referencia, evaluada con las Bases de Cierre Mensual:

- Malo: primer evento, dentro de la ventana, de (a) atraso > 60 días en cualquier PP, (b) castigo, o (c) refinanciación.
- Bueno: atraso máximo ≤ 8 días durante toda la ventana de desempeño.
- Indeterminado: atraso entre 8 y 60 días sin alcanzar evento de malo (excluido del desarrollo).

Muestra	Total	Buenos (Cant)	Malos (Cant)	% de buenos	% de malos
Train	461'803	395'302	66'501	85.6	14.4
Test	197'664	168'984	28'680	85.5	14.5
OOT	148'156	131'922	16'234	89	11

A continuación compartimos la vista de la distribucion del volumen de la PO sobre los periodos antes del muestreo




Figura 1. Distribución del volumen de la PO por periodo (base completa).

La Figura 2 muestra la distribución del volumen una vez aplicado el muestreo, diferenciando los conjuntos de desarrollo y validación.




Figura 2. Distribución del volumen de la PO tras el muestreo (desarrollo y validación).

Las Figuras 3, 4 y 5 presentan la distribución del volumen por periodo en los conjuntos de entrenamiento (train), prueba (test) y *out-of-time* (OOT), respectivamente.




Figura 3. Distribución del volumen de la PO en el conjunto de entrenamiento (train).



Figura 4. Distribución del volumen de la PO en el conjunto de prueba (test).




Figura 5. Distribución del volumen de la PO en el conjunto *out-of-time* (OOT).

3. Data

3.1 Fuentes

Las fuentes utilizadas para la extracción de variables provienen de:

- Variables Sociodemográficas
- Variables RCC
- Variables de Pasivos y Activos Interbank
- Variables de Transacciones
- Variables Adhoc Reenganche (Capacidad de Pago y Cuotas)
- Variables de Fuente INTERCORP

3.2 Selección de variables

La metodología para la selección de variables más relevantes dentro del modelo se basa en ocho etapas clave:

1. **Limpieza de variables:** Se comienza identificando y clasificando las variables según su contenido, aplicando procesos de limpieza y ajustando sus formatos. Este paso incluye la transformación de variables cuando sea necesario, y la exclusión de aquellas que no aportan valor al modelo, asegurando que solo se utilicen datos consistentes y útiles.
2. **Manejo de datos faltantes (missings):** En esta etapa, se analiza el porcentaje de datos faltantes por cada variable. Se eliminan aquellas variables que superan el 95% de datos incompletos, priorizando el uso de variables que ofrecen mayor cantidad de información útil para el modelo, reduciendo el riesgo de sesgos en las predicciones.
3. **Filtro de varianza nula:** Se eliminan las variables constantes (desviación estándar igual a cero).
4. **Modelo de importancia (LightGBM):** Sobre las variables sobrevivientes se entrena un modelo LightGBM de propósito de selección, para evaluar la importancia de cada variable en la predicción. Aquellas variables que no aportan significativamente (con una importancia inferior al 0.1%) a la capacidad predictiva del modelo son descartadas, mientras que las variables de mayor contribución se mantienen para garantizar el mejor rendimiento del modelo.
5. **Correlación:** Se identifican las variables que presentan correlación absoluta superior a 0.80 entre sí, se conserva la de mayor importancia SHAP y se descarta la otra, resolviendo la multicolinealidad sin sacrificar poder predictivo. Las variables que aporten información duplicada o irrelevante se eliminan o se combinan para optimizar la eficiencia y precisión del modelo.
6. **Poder discriminante univariado mínimo (Gini):** Se descartan las variables cuyo Gini univariado es inferior a 2%, eliminando variables sin capacidad discriminante individual relevante. El Gini se estima ajustando y evaluando un clasificador univariado sobre Train+Test.
7. **Estabilidad temporal (PSI Train vs OOT):** Para cada variable se calcula el Índice de Estabilidad Poblacional (PSI) entre Train+Test y OOT. Se aplica un esquema de semáforo: verde ($PSI \leq 0.10$), amarillo ($0.10 < PSI \leq 0.25$, variable retenida con alerta de monitoreo) y rojo ($PSI > 0.25$, variable descartada por inestabilidad).
8. **Sentido de negocio:** Finalmente, las variables seleccionadas son revisadas desde una perspectiva de negocio para asegurar que sean relevantes en términos prácticos. Esto implica verificar que las variables no solo sean útiles desde un punto de vista técnico, sino que también aporten valor al contexto del problema que se busca resolver, asegurando que tengan una aplicación tangible y coherente con los objetivos del negocio.

Esta metodología asegura que el conjunto final de variables utilizadas en el modelo sea robusto, eficiente y esté alineado tanto con las necesidades técnicas como con las prioridades del negocio.

A continuación, se muestra el número de variables por fuente que iniciaron y se filtraron en este proceso:

Fuente	Variables Iniciales	Variables Finales
Consolidado de Stock de Modelos	276	40
Capacidad de Pago	38	1

Fuente	Variables Iniciales	Variables Finales
Cuotas	99	1
Intercorp	6455	6

Cabe precisar que las cifras de la tabla anterior corresponden a la presente versión del modelo. En esta segunda versión se excluyeron las dos variables provenientes de la fuente SuSalud —contenidas en la fuente Consolidado de Stock de Modelos—, en cumplimiento de los lineamientos de privacidad de datos personales. Asimismo, durante la evaluación de consistencia entre el entorno de desarrollo y el entorno productivo, se identificó que el porcentaje de coincidencia de variables entre ambas versiones no alcanzaba un nivel significativo, lo cual constituyó un motivo adicional para reentrenar el modelo utilizando el dataset de la versión productiva, garantizando así la trazabilidad y consistencia entre el insumo de desarrollo y el de implementación.

Como consecuencia de dicha exclusión y del reentrenamiento sobre la base productiva, se reejecutó íntegramente el proceso de selección de variables descrito en las ocho etapas precedentes. En esta reestimación, cuatro variables adicionales registraron una importancia SHAP relativa inferior al umbral de 0.1% definido en la etapa 4 (modelo de importancia), por lo que fueron descartadas conforme al criterio establecido; tres de ellas provenían de la fuente Consolidado de Stock de Modelos y una de la fuente Intercorp. De este modo, el conjunto final de variables explicativas se redujo de 54, en la primera versión, a 48 en la versión actual, sin que ello comprometa el desempeño ni la estabilidad del modelo, conforme se evidencia en las secciones de resultados correspondientes.

3.3 Procesamiento de datos

Tratamiento de variables de fuente Intercorp

Las variables provenientes de la fuente INTERCORP no se incorporan al modelo en su valor crudo, sino que se transforman previamente mediante discretización supervisada (binning). Para cada variable se ajusta un árbol de decisión univariado contra la variable objetivo, de modo que los puntos de corte maximicen la separación respecto al target, en lugar de emplear cortes arbitrarios. Se selecciona la configuración con el mejor balance entre granularidad y monotonía, priorizando un mayor número de tramos válidos y una relación monótona entre el tramo y la tasa de malos (correlación de Spearman). Los tramos se definen como intervalos cerrados por la derecha, de la forma (límite inferior, límite superior]. Los valores faltantes se asignan a una categoría independiente (categoría 0).

Maapeo de Variables (Binning)

Variable Original	Intervalo	Categoría Asignada
trf_mtomax_grifos_pos12m	(-inf, 38.1099]	1
trf_mtomax_grifos_pos12m	(38.1099, 64.8899]	2
trf_mtomax_grifos_pos12m	(64.8899, 118.1850]	3
trf_mtomax_grifos_pos12m	(118.1850, 240.0650]	4
trf_mtomax_grifos_pos12m	(240.0650, +inf)	5
trf_far_mtomax_med_12m	(-inf, 10.9099]	1

Variable Original	Intervalo	Categoría Asignada
trf_far_mtomax_med_12m	(10.9099, 35.3050]	2
trf_far_mtomax_med_12m	(35.3050, 55.6900]	3
trf_far_mtomax_med_12m	(55.6900, 113.2200]	4
trf_far_mtomax_med_12m	(113.2200, +inf)	5
trf_mtot_tc_retail_pos1m	(-inf, 34.8350]	1
trf_mtot_tc_retail_pos1m	(34.8350, 172.8500]	2
trf_mtot_tc_retail_pos1m	(172.8500, 602.2850]	3
trf_mtot_tc_retail_pos1m	(602.2850, 1050.1650]	4
trf_mtot_tc_retail_pos1m	(1050.1650, +inf)	5
trf_prm_restaur_pos_6m	(-inf, 29.9786]	1
trf_prm_restaur_pos_6m	(29.9786, 43.0713]	2
trf_prm_restaur_pos_6m	(43.0713, 84.6658]	3
trf_prm_restaur_pos_6m	(84.6658, 107.6036]	4
trf_prm_restaur_pos_6m	(107.6036, +inf)	5
trf_mtoprm_altagama_12m	(-inf, 13.5928]	1
trf_mtoprm_altagama_12m	(13.5928, 25.5048]	2
trf_mtoprm_altagama_12m	(25.5048, 50.0482]	3
trf_mtoprm_altagama_12m	(50.0482, +inf)	4
trf_mto_salud_u24m	(-inf, 129.8950]	1
trf_mto_salud_u24m	(129.8950, 452.5350]	2
trf_mto_salud_u24m	(452.5350, 1385.5650]	3
trf_mto_salud_u24m	(1385.5650, +inf)	4

A continuación se presenta, para cada variable transformada, la distribución porcentual de observaciones y la tasa de malos por tramo (*bin*). Este análisis permite verificar la monotonía de la relación entre los tramos de la variable y la tasa de incumplimiento, así como evaluar la representatividad de cada tramo, criterios que sustentan la calidad de la transformación aplicada.

Tabla de Distribución y Monotonía para: trf_mtoprm_altagama_12m

trf_mtoprm_altagama_12m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
0	105'142	18'279	22.77	17.39
1	24'473	4'582	5.3	18.72
2	31'303	5'221	6.78	16.68
3	64'803	9'358	14.03	14.44
4	236'082	29'061	51.12	12.31

Tabla de Distribución y Monotonía para: trf_mtomax_grifos_pos12m

trf_mtomax_grifos_pos12m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
0	224'832	33'823	48.69	15.04
1	34'339	5'992	7.44	17.45
2	35'453	5'867	7.68	16.55
3	45'148	6'679	9.78	14.79
4	81'496	9'900	17.65	12.15
5	40'535	4'240	8.78	10.46

Tabla de Distribución y Monotonía para: trf_mtoto_tc_retail_pos1m

trf_mtoto_tc_retail_pos1m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
0	75'391	14'342	16.33	19.02
1	148'409	24'184	32.14	16.3
2	45'314	6'369	9.81	14.06
3	76'462	9'309	16.56	12.17
4	40'191	4'375	8.7	10.89
5	76'036	7'922	16.47	10.42

Tabla de Distribución y Monotonía para: trf_far_mtomax_med_12m

trf_far_mtomax_med_12m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
0	71'409	11'777	15.46	16.49
1	37'007	6'378	8.01	17.23
2	108'358	17'258	23.46	15.93
3	65'886	9'493	14.27	14.41
4	103'530	13'411	22.42	12.95
5	75'613	8'184	16.37	10.82

Tabla de Distribución y Monotonía para: trf_mto_salud_u24m

trf_mto_salud_u24m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
0	263'543	42'100	57.07	15.97
1	38'533	5'403	8.34	14.02
2	55'431	7'423	12	13.39
3	52'354	6'179	11.34	11.8
4	51'942	5'396	11.25	10.39

Tabla de Distribución y Monotonía para: trf_prm_restaur_pos_6m

trf_prm_restaur_pos_6m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
0	149'194	23'897	32.31	16.02
1	32'917	5'608	7.13	17.04

trf_prm_restaur_pos_6m	Cant_Obs	Cant_Malos	% Obs	Tasa_Malos (%)
2	39'741	6'228	8.61	15.67
3	134'241	18'949	29.07	14.12
4	42'381	5'223	9.18	12.32
5	63'329	6'596	13.71	10.42

Variables con Imputación

Las siguientes variables fueron imputadas con valor 0 ante datos faltantes y convertidas a tipo categórico. El tratamiento aplica a dos grupos:

(i) Variables indicador (flag):

- flg_pasibk
- flg_labdp

(ii) Variables discretizadas de la fuente Intercorp (versión bineada, donde la categoría 0 corresponde a los valores faltantes):

- trf_mtoprm_altagama_12m
- trf_mtot_tc_retail_pos1m
- trf_far_mtymax_med_12m
- trf_mtoymax_grifos_pos12m
- trf_mto_salud_u24m
- trf_prm_restaur_pos_6m

3.4 Análisis descriptivo

Con el fin de obtener un conocimiento general de la información disponible y, al mismo tiempo, detectar posibles errores, valores atípicos y ausencia de información, se realiza un análisis descriptivo de las variables.

Para cada variable continua se calcula un conjunto de estadísticas de resumen que permiten evaluar su completitud, tendencia central, dispersión y forma de la distribución:

- **N Obs:** número de casos válidos (no faltantes).
- **N Missing:** número de casos con valor faltante.
- **% Missing:** porcentaje de casos con valor faltante (fill rate complementario).
- **Media / Mediana:** medidas de tendencia central.
- **Desv. Std:** desviación estándar (medida de dispersión).
- **Mínimo:** valor mínimo observado.
- **Máximo:** valor máximo observado.
- **P1, P5, P25, P50, P75, P90, P95, P99:** percentiles 1, 5, 25, 50, 75, 90, 95 y 99 de la distribución, que permiten evaluar la presencia de valores extremos y la forma de la distribución.

Para las variables categóricas, las estadísticas reportadas son:

- **Categoría:** valor de la categoría de la variable.
- **N:** número de casos en la categoría.
- **%:** porcentaje que representa la categoría sobre el total.
- **% Acum.:** porcentaje acumulado hasta la categoría.

El detalle completo del análisis descriptivo, a nivel de cada variable candidata, se encuentra en el anexo "Análisis de Variables Comportamental PP Foco Reenganche v2" (formato Excel).

3.5 Análisis Temporal

El análisis temporal extiende el análisis descriptivo incorporando el componente temporal, con el fin de observar cambios relevantes en el comportamiento de las variables a lo largo del tiempo y detectar posibles cambios estructurales en la información. Para ello, en cada mes observado se analiza la distribución de cada variable mediante un conjunto de estadísticos descriptivos:

- **Non_missing:** porcentaje de casos válidos (*fill rate*).
- **Missing values:** número de registros con valor faltante.
- **Mean:** media de la variable.
- **Median:** mediana (segundo cuartil) de la variable.
- **Q1 (1st Qu.):** primer cuartil (percentil 25).
- **Q3 (3rd Qu.):** tercer cuartil (percentil 75).

El seguimiento mes a mes de estos estadísticos permite verificar la estabilidad de las variables candidatas durante el periodo de desarrollo, identificando desplazamientos en la tendencia central, cambios en la dispersión o variaciones en la completitud (*fill rate*) que pudieran comprometer la robustez del modelo.

El detalle completo de los descriptivos temporales, a nivel de cada variable y periodo, se encuentra en el anexo "*Analisis_Descriptivo_Temporal_v2.pdf*".

3.6 Análisis Bivariado

El análisis bivariado se realiza con tres objetivos:

- 1) Evaluar la calidad y distribución de cada variable candidata: se examina la presencia de valores atípicos, el porcentaje de valores ausentes y las concentraciones en determinados valores. Este análisis permite estimar la calidad de la información e identificar variables que, por distintas causas, no reúnen los requisitos necesarios para ser consideradas en etapas posteriores.
- 2) Estimar el poder predictivo individual de cada variable respecto a la variable objetivo, como primera aproximación a su capacidad discriminante.
- 3) Analizar las correlaciones entre las variables candidatas, con el fin de identificar redundancias y potenciales problemas de multicolinealidad.

Adicionalmente, se verifica que la tendencia de la tasa de malos a lo largo de los tramos de cada variable sea coherente con el sentido de negocio esperado (monotonía y dirección de la relación riesgo-variable). Esta validación asegura que las variables seleccionadas no solo aporten poder predictivo, sino que mantengan una interpretación de negocio consistente y defendible.

El detalle de los gráficos bivariados por variable se presenta en el anexo "*Bivariado_Modelo_Comp_PP_Reenganche_v2.pdf*", y la matriz de correlación entre variables candidatas en el anexo "*Matriz_correlacion_v2.pdf*".

- Máxima correlación: *antig_profesional* - *edad* = 0.779
- Mínima correlación: *rat_maxsldppibk_03m* - *flg_pasibk* = -0.649

4. Modelamiento

4.1 Metodología

CatBoost (Categorical Boosting)

Es un framework de gradient boosting basado en árboles de decisión, desarrollado con un enfoque orientado al tratamiento nativo de variables categóricas y a la reducción del sobreajuste. Está diseñado para ofrecer un desempeño robusto con las siguientes ventajas:

1. Tratamiento nativo de variables categóricas mediante estadísticos ordenados (*ordered target statistics*), sin requerir transformaciones previas como *one-hot encoding*.
2. Reducción del sesgo de predicción (*prediction shift*) mediante el esquema de *ordered boosting*, lo que mitiga el sobreajuste.
3. Desempeño competitivo con configuraciones por defecto, reduciendo la sensibilidad del modelo a la calibración de hiperparámetros.
4. Soporte de entrenamiento en CPU y GPU, así como de esquemas de cómputo distribuido.
5. Tiempos de inferencia reducidos, atributo relevante para el despliegue del modelo en entornos productivos.

Dado que se basa en algoritmos de árboles de decisión, CatBoost construye árboles simétricos (*oblivious trees*), en los cuales se aplica la misma condición de partición a todos los nodos de un mismo nivel de profundidad. Esta arquitectura contrasta con los esquemas de crecimiento hoja por hoja (*leaf-wise*) o por niveles con particiones heterogéneas (*level-wise*) empleados por otros algoritmos de *boosting*, en los que cada nodo puede dividirse mediante condiciones distintas.

La estructura simétrica actúa como un mecanismo de regularización implícita, al restringir la complejidad de cada árbol individual, lo que contribuye a la estabilidad y capacidad de generalización del modelo. Adicionalmente, esta arquitectura permite representar cada árbol como una tabla de decisión compacta, lo que se traduce en una evaluación (*scoring*) altamente eficiente en producción. Por su parte, el esquema de *ordered boosting* calcula los residuos de cada observación utilizando modelos entrenados sin dicha observación, evitando la fuga de información (*target leakage*) inherente a los esquemas de boosting tradicionales.

Para obtener más detalles, consulte la [documentación oficial de CatBoost](#).

4.2 Concepto de los hiperparámetros

A continuación se especifican los conceptos de los hiperparámetros utilizados en la configuración del modelo CatBoost (Categorical Boosting):

- Función de pérdida (*loss_function*): función objetivo a minimizar durante el entrenamiento; se emplea *Logloss* (pérdida logarítmica), adecuada para problemas de clasificación binaria como la predicción de incumplimiento.
- Métrica de evaluación (*eval_metric*): métrica utilizada para evaluar el desempeño del modelo sobre el conjunto de validación durante el entrenamiento.
- Número de divisiones por variable (*border_count*): número máximo de puntos de corte (*splits*) considerados en la discretización de las variables numéricas para la construcción de los árboles; controla la granularidad de las particiones y el costo computacional.
- Semilla (*random_seed*): semilla que controla la aleatoriedad del proceso (submuestreo de registros y variables), garantizando la reproducibilidad de los resultados.
- Número de hilos (*thread_count*): número de hilos de procesamiento utilizados durante el entrenamiento; el valor -1 indica el uso de todos los núcleos disponibles.
- Nivel de detalle de salida (*verbose*): controla la cantidad de mensajes informativos emitidos durante el entrenamiento.
- Escritura de archivos auxiliares (*allow_writing_files*): indica si el framework genera archivos auxiliares de registro (*logs* y *snapshots*) durante el entrenamiento; se desactiva para mantener un entorno de ejecución controlado.
- Ponderación de clases (*class_weights*): factores de peso asignados a cada clase de la variable objetivo, que compensan el desbalance de clases otorgando mayor importancia a la clase minoritaria (eventos de incumplimiento).

- Selección del mejor modelo (`use_best_model`): indica si, al finalizar el entrenamiento, se conserva la iteración con mejor desempeño sobre el conjunto de validación, en lugar de la última iteración ejecutada.
- Número de iteraciones (`iterations`): número máximo de árboles de decisión (estimadores) que se construyen secuencialmente en el proceso de boosting.
- Política de crecimiento (`grow_policy`): esquema de construcción de los árboles; el valor *SymmetricTree* corresponde a árboles simétricos (*oblivious trees*), en los que se aplica la misma condición de partición a todos los nodos de un mismo nivel, actuando como mecanismo de regularización implícita.
- Tipo de muestreo (`bootstrap_type`): esquema de submuestreo de registros empleado en cada iteración; el esquema *Bernoulli* selecciona cada observación de forma independiente con una probabilidad definida por el parámetro de submuestreo.
- Profundidad (`depth`): profundidad de los árboles del proceso de boosting, que controla la complejidad del modelo; en árboles simétricos determina de manera directa el número de hojas (2^{depth}).
- Regularización L2 (`l2_leaf_reg`): penalización L2 aplicada sobre los valores de las hojas, que favorece la simplicidad del modelo y reduce el sobreajuste.
- Ratio de aprendizaje (`learning_rate`): factor de reducción o encogimiento (*shrinkage*) aplicado a la contribución de cada nuevo árbol.
- Fracción de variables (`rsm`): proporción de variables seleccionadas aleatoriamente en cada división (*Random Subspace Method*), lo que reduce la correlación entre árboles y el sobreajuste.
- Fracción de submuestreo de registros (`subsample`): proporción de la muestra de entrenamiento seleccionada aleatoriamente para construir cada árbol, conforme al esquema de muestreo definido en *bootstrap_type*, lo que introduce aleatoriedad y reduce el sobreajuste.
- Intensidad de aleatoriedad (`random_strength`): magnitud del ruido aleatorio añadido a la puntuación de las divisiones candidatas al construir cada árbol, lo que incrementa la diversidad de los árboles y reduce el sobreajuste.
- Rondas de parada temprana (`early_stopping_rounds`): número de iteraciones consecutivas sin mejora en la métrica de evaluación sobre el conjunto de validación tras las cuales se detiene el entrenamiento, evitando el sobreajuste y reduciendo el costo computacional.

4.3 Hiperparámetros del modelo

Los hiperparámetros óptimos se obtuvieron usando la técnica de grid search. Dichos valores se muestran a continuación

	hyperparameter	value
0	loss_function	Logloss
1	eval_metric	Logloss
2	border_count	128
3	random_seed	1234
4	thread_count	-1
5	verbose	False
6	allow_writing_files	False
7	use_best_model	True
8	iterations	3000
9	grow_policy	SymmetricTree
10	bootstrap_type	Bernoulli
11	depth	3
12	l2_leaf_reg	9.041421501376188

	hyperparameter	value
13	learning_rate	0.04790766831601822
14	rsm	0.5413121116084815
15	subsample	0.5394918439653147
16	random_strength	1.9821179237472073
17	early_stopping_rounds	50

Nota técnica: Cabe precisar que, si bien algunos de los valores de los hiperparámetros finales se encuentran fuera de los rangos sugeridos por el manual de desarrollo de modelos, esta configuración se ha seleccionado deliberadamente con el fin de robustecer el modelo y evitar el sobreajuste (overfitting) dadas las particularidades de la data, garantizando así una mejor capacidad de generalización.

4.4 Comparativa de Modelos y Resultados

Para la comparativa de modelos se evaluaron tres algoritmos avanzados de machine learning: CatBoost, LightGBM y XGBoost, sobre diferentes versiones del conjunto de variables predictoras. La evaluación se realizó en los conjuntos de entrenamiento (Train), prueba (Test) y Out-of-Time (OOT), con el propósito de analizar la capacidad predictiva y la estabilidad temporal de los modelos frente a nuevos periodos de información.

El punto de corte óptimo utilizado para calcular las métricas de clasificación (Accuracy, Precision, Recall, Specificity y F1-Score) fue determinado mediante el criterio de Youden ($J = \text{TPR} - \text{FPR}$), aplicando la función encontrar_umbral_optimo, que selecciona el umbral que maximiza la separación entre clientes buenos y malos pagadores. A continuación, se presenta un resumen comparativo de los resultados obtenidos de modelos:

1. CatBoost

Dataset	AUC	Gini	K-S	Accuracy	Precision	Recall	Specificity	F1-Score
Train	89.13%	78.26%	60.70%	81.22%	41.94%	79.13%	81.57%	54.82%
Test	87.40%	74.79%	57.52%	80.39%	40.63%	76.28%	81.08%	53.02%
OOT	88.08%	76.15%	58.83%	84.46%	38.83%	72.72%	85.90%	50.63%

2. XGBoost

Dataset	AUC	Gini	K-S	Accuracy	Precision	Recall	Specificity	F1-Score
Train	89.34%	78.68%	61.13%	81.85%	42.91%	78.76%	82.37%	55.55%
Test	87.39%	74.77%	57.55%	80.95%	41.42%	75.65%	81.85%	53.53%
OOT	88.01%	76.02%	58.78%	84.87%	39.52%	71.84%	86.47%	50.99%

3. LightGBM

Dataset	AUC	Gini	K-S	Accuracy	Precision	Recall	Specificity	F1-Score
Train	89.03%	78.05%	60.49%	81.72%	42.65%	78.17%	82.32%	55.19%
Test	87.32%	74.65%	57.55%	81.05%	41.58%	75.56%	81.98%	53.64%
OOT	87.96%	75.92%	58.53%	84.89%	39.55%	71.63%	86.52%	50.96%

Conclusión comparativa. Los tres algoritmos exhiben un desempeño elevado y consistente entre los conjuntos de entrenamiento, prueba y out-of-time, sin evidencia de sobreajuste

relevante: la caída de Gini entre Train y Test es moderada en los tres casos (CatBoost: 78.26% → 74.79%) y el desempeño se recupera en el conjunto OOT (CatBoost: 76.15%), lo que confirma estabilidad temporal.

En términos de capacidad discriminante —métricas independientes del punto de corte y, por tanto, las más adecuadas para comparar modelos— CatBoost presenta el mejor desempeño en los conjuntos fuera de muestra, que constituyen el criterio determinante de generalización: lidera en AUC y Gini tanto en Testing (AUC 87.40%, Gini 74.79%) como en OOT (AUC 88.08%, Gini 76.15%), así como en K-S sobre el conjunto OOT (58.83%). Si bien XGBoost alcanza el mejor desempeño en el conjunto de entrenamiento (Gini 78.68%), esta ventaja no se sostiene fuera de muestra, lo que sugiere un mayor grado de ajuste a la muestra de desarrollo; LightGBM, por su parte, se ubica de forma sistemática en tercer lugar en los conjuntos de evaluación, con diferencias pequeñas pero consistentes.

Adicionalmente, CatBoost registra el mayor Recall en los tres conjuntos (Train: 79.13%; Test: 76.28%; OOT: 72.72%), lo que se traduce en una mayor capacidad de captura de los eventos de incumplimiento, atributo prioritario dada la asimetría de costos asociada a la no detección de clientes de alto riesgo. Si bien XGBoost y LightGBM alcanzan mayor Accuracy, Precision y F1-Score en algunos conjuntos, estas métricas dependen del umbral de clasificación seleccionado y reflejan un balance distinto entre Recall y Specificity, no una mayor capacidad de ordenamiento de riesgo. Dado que el objetivo del modelo es discriminar el riesgo de incumplimiento (ordenamiento por PD), las métricas de poder discriminante (AUC, Gini, K-S) evaluadas fuera de muestra son las determinantes. Por su desempeño superior y consistente en estas métricas sobre los conjuntos de Testing y OOT, se selecciona CatBoost como algoritmo definitivo.

4.4.1 Función de Pérdida

Durante el proceso de entrenamiento del modelo **CatBoostClassifier**, se empleó como función objetivo la **LogLoss** (pérdida logarítmica o entropía cruzada binaria), la cual cuantifica la discrepancia entre las probabilidades predichas por el modelo y las etiquetas observadas del evento de incumplimiento. Esta función es el estándar en problemas de clasificación binaria con salida probabilística, dado que penaliza de forma más severa aquellas predicciones emitidas con alta confianza que resultan incorrectas, lo cual es una propiedad deseable en la estimación de probabilidades de default calibradas.

La expresión general de la LogLoss es:

$$L = -(1/N) \cdot \sum_{i=1}^N [y_i \cdot \log(\hat{p}_i) + (1 - y_i) \cdot \log(1 - \hat{p}_i)]$$

donde:

- y_i : etiqueta real de la observación i (1 = cliente que incurre en mora mayor a 60 días; 0 = cliente que no incurre en el evento),
- $\hat{p}_i$: probabilidad de incumplimiento estimada por el modelo para el cliente i ,
- N : número total de observaciones del conjunto evaluado.

Durante el entrenamiento se registró la evolución de la LogLoss tanto en el conjunto de entrenamiento (*Train*) como en el conjunto de validación (*Test*), con el propósito de monitorear la convergencia del algoritmo y prevenir el sobreajuste (*overfitting*) mediante el mecanismo de *Early Stopping*.

En la gráfica se observa la evolución de la función de pérdida a lo largo de las iteraciones del proceso de *boosting*. Ambas curvas exhiben un descenso pronunciado durante las primeras iteraciones —reflejo de la rápida captura de los patrones predictivos dominantes— seguido de una fase de estabilización asintótica conforme el modelo refina de manera incremental su ajuste. La brecha (*gap*) entre la curva de entrenamiento y la de validación se mantiene

acotada y estable a lo largo de todo el proceso, sin evidencia de divergencia ni de repunte en la pérdida de validación, lo cual indica que el modelo generaliza adecuadamente y no presenta signos de sobreajuste severo. Finalmente, el criterio de *Early Stopping* determinó la **iteración óptima en 1371** (línea vertical discontinua), punto en el que la LogLoss del conjunto de validación alcanza su valor mínimo; el modelo final se retiene en dicha iteración con el fin de maximizar su capacidad de generalización sobre datos no observados.




Figura 6. Evolución de la función de pérdida (LogLoss) durante el entrenamiento

4.4.2 Tabla de Eficiencia

La Tabla de Eficiencia evalúa la capacidad de ordenamiento del modelo de PD sobre la muestra **Out-of-Time (OOT)**, segmentando a la población en diez deciles ordenados de forma descendente según la PD estimada por el clasificador **CatBoost** (Decil 1 = mayor riesgo). Su análisis es indispensable para verificar dos condiciones: (i) la **monotonía** de la tasa de malos observada, requisito para la construcción de bandas de riesgo y evidencia de un ordenamiento consistente del score; y (ii) la **granularidad** de la segmentación, reflejada en rangos de PD contiguos y no solapados que garanticen una adecuada resolución entre niveles de riesgo.

Tabla de Eficiencia por Deciles — Muestra OOT

Tramo	Cli- entes (N)	% Po- bla- ción	Malos (Y=1)	Buenos (Y=0)	Tasa Malos Obs.	PD Mín- ima	PD Promedio	PD Máx- ima	Cap- tura Malos Acum.	KS Tramo	Lift
1	14,816	10.0%	9,018	5,798	60.87%	68.04%	86.75%	99.95%	55.55%	51.16%	5.55
2	14,815	10.0%	2,692	12,123	18.17%	47.47%	56.46%	68.03%	72.13%	58.55%	1.66
3	14,816	10.0%	1,504	13,312	10.15%	35.67%	41.14%	47.47%	81.40%	57.72%	0.93
4	14,815	10.0%	1,039	13,776	7.01%	27.51%	31.39%	35.67%	87.80%	53.68%	0.64
5	14,816	10.0%	734	14,082	4.95%	21.09%	24.17%	27.51%	92.32%	47.53%	0.45

Tramo	Cli- entes (N)	% Po- bla- ción	Malos (Y=1)	Buenos (Y=0)	Tasa Malos Obs.	PD Mín- ima	PD Promedio	PD Máx- ima	Cap- tura Malos Acum.	KS Tramo	Lift
6	14,815	10.0%	476	14,339	3.21%	15.99%	18.47%	21.09%	95.25%	39.59%	0.29
7	14,816	10.0%	336	14,480	2.27%	11.73%	13.80%	15.99%	97.32%	30.68%	0.21
8	14,815	10.0%	256	14,559	1.73%	8.03%	9.85%	11.73%	98.90%	21.22%	0.16
9	14,816	10.0%	132	14,684	0.89%	4.57%	6.29%	8.03%	99.71%	10.91%	0.08
10	14,816	10.0%	47	14,769	0.32%	0.06%	2.71%	4.57%	100.0%	0.00%	0.03

Nota: Tasa de malos global (OOT) = **10.96%**. KS máximo global = **58.55%** (Decil 2).

Monotonía. La tasa de malos observada es **estrictamente decreciente**, desde 60.87% (Decil 1) hasta 0.32% (Decil 10), sin quiebres en ningún tramo (**monotonía decreciente: Sí**). El modelo ordena consistentemente el riesgo fuera de la ventana de desarrollo, y los rangos de PD por decil son contiguos y no solapados, confirmando una granularidad adecuada.

Discriminación. El Decil 1 concentra el **55.55% de los malos** de la muestra con solo el 10% de la población, y con los dos primeros deciles la captura acumulada alcanza el 72.13%. El **KS máximo de 58.55%** (Decil 2) evidencia una excelente separación entre poblaciones sanas y en mora. El **Lift de 5.55** del Decil 1 indica que este segmento presenta una tasa de malos más de 5 veces superior a la global (10.96%), lo que habilita estrategias diferenciadas de gestión y cobranza preventiva.

A continuación se presenta el gráfico de eficiencia sobre la muestra OOT, donde las barras azules corresponden a la tasa de malos observada por decil y la línea roja con marcadores a la PD promedio estimada, con el eje ordenado de forma descendente por riesgo (Decil 1 = mayor riesgo). Su lectura conjunta permite verificar visualmente la monotonía y la consistencia de la calibración descritas.




Figura 7. Gráfico de Eficiencia sobre OOT

4.5 Importancia de variables por Shap Value Mean

La idea detrás de la importancia de las características SHAP es simple: las características con valores absolutos grandes de Shapley son importantes. Como queremos la importancia global, promediamos los valores absolutos de Shapley por característica en los datos. Luego para calcular la importancia por SHAP de cada variable, relativizamos el shap mean asociado a cada variable entre la sumatoria de todos los shap mean de las variables. (Ver detalle excel adjunto)

La importancia de la característica SHAP es una alternativa a la importancia de la característica de permutación. Existe una gran diferencia entre ambas medidas de importancia: la importancia de la característica de permutación se basa en la disminución del rendimiento del modelo. SHAP se basa en la magnitud de las atribuciones de características. En esta sección se mostrará el grado de importancia de cada variable por shap value mean relativizada.

N	Feature	Descripción	SHAP Value	Importancia Relativa
1	cnt_gestiones_6m	Cantidad de gestiones de cobranza en los U6M	0.38	7.2%
2	max_clfibk_06m	Máxima clasificación de riesgo en IBK U6M	0.31	5.7%
3	num_inc_sld_tip_pas_12m	Número de incrementos del saldo en productos pasivos U12M	0.30	5.6%
4	rat_saldo_rt_t1_t12	Ratio entre saldo reciente y saldo máximo anual en productos rotativos	0.28	5.3%
5	cnt_dias_adelanto_atraso	Días entre pago y vencimiento (negativo = anticipado, positivo = atrasado)	0.25	4.7%
6	porc_avg_pctusotctot_u1a	Porcentaje promedio de uso de TC U1A	0.21	4.0%
7	avg_diamorasldppibk_12m	Promedio de días de mora en saldo PP IBK U12M	0.20	3.8%
8	cnt_atraso_01_aj	Máximo de días de atraso en el mes 1, para clientes sin atraso en el mes evaluado (mes 0)	0.19	3.6%
9	num_vehiculos	Número de vehículos registrados	0.19	3.5%
10	min_pasctasld_03m	Saldo mínimo en cuenta sueldo U3M	0.18	3.5%
11	num_edad	Edad del cliente	0.16	3.0%
12	std_datraso_rd_u1a	Desviación estándar de días de atraso U1A	0.14	2.7%
13	rat_comparacion_u1m_u12m	Ratio entre el saldo del último mes y el promedio U12M	0.14	2.6%
14	cnt_deccorreg_12m	Cantidad de decrementos corregidos U12M	0.13	2.5%
15	num_inmuebles	Número de propiedades inscritas en SUNARP	0.13	2.5%
16	flg_pasibk	Indicador si el cliente tiene pasivos en IBK	0.12	2.3%
17	max_dias_atraso_no_ibk_3m	Máximo días de atraso en entidades no IBK U3M	0.12	2.3%
18	flg_labdp	Indicador si el cliente es laboralmente dependiente	0.11	2.1%
19	num_titulo_prof	Número de títulos profesionales del cliente	0.11	2.0%
20	cnt_dectcttotal_12m	Cantidad de decrementos totales en tarjeta de crédito U12M	0.10	2.0%
21	ant_profesional	Antigüedad profesional en años	0.10	2.0%

N	Feature	Descripción	SHAP Value	Importancia Relativa
22	rat_maxsldppibk_03m	Ratio máximo de saldo PP IBK U3M	0.10	1.9%
23	avg_trxtot12m	Promedio de transacciones totales U12M	0.10	1.8%
24	avg_dda_tlc_12m	Promedio de días de atraso en servicios de telecomunicaciones U12M	0.10	1.8%
25	avg_slldispefpn_u6m	Promedio de saldo disponible efectivo U6M	0.09	1.7%
26	max_dda_pp_rat_9m	Máximo ratio de deuda PP U9M	0.09	1.7%
27	rat_sld_pp_u1m_tc_ibk	Ratio de saldo en productos PP en 1 mes respecto a TC IBK	0.08	1.5%
28	sld_beta_pc_pp_1a	Sensibilidad/variabilidad del saldo personal U1A	0.07	1.3%
29	trf_mtoprmltagama_12m	Monto promedio de transacciones/productos de alta gama U12M	0.06	1.1%
30	porc_avg_sld_rd_6m	Porcentaje promedio de saldo en productos RD U6M	0.05	1.0%
31	med_dec_sld_tarj_3i_6m	Mediana del decrecimiento del saldo en tarjetas de crédito en 3 instancias U6M	0.05	1.0%
32	rat_actpas_03m	Ratio activos/pasivos U3M	0.05	1.0%
33	trf_mtomax_grifos_pos12m	Monto máximo de transacción POS en rubro Grifos U12M	0.05	0.9%
34	trf_mtot_tc_retail_pos1m	Monto total consumido por el cliente con TC en transacciones Retail/POS U1M	0.05	0.9%
35	mto_dda_otr_emp_12m	Monto de deuda con otros empleadores U12M	0.05	0.9%
36	rat_svoctrppeallsf_3m	Ratio de saldo vigente en otras entidades U3M	0.04	0.8%
37	mto_totalrec06m	Monto total recibido U6M	0.04	0.8%
38	trf_mto_salud_u24m	Monto total de consumo del cliente en sector Salud U24M	0.04	0.8%
39	trf_far_mtomax_med_12m	Monto neto máximo de compra en Farmacias Peruanas - Medicamento U12M	0.04	0.8%
40	ant_primer_producto	Antigüedad del primer producto financiero en meses	0.04	0.8%
41	med_sld_sa_hip_3i_6m	Mediana del saldo en productos hipotecarios U6M	0.04	0.7%
42	trf_prm_restaur_pos_6m	Monto promedio por transacción en Restaurantes U6M	0.04	0.7%
43	avg_rat_dispefpnj_u1a	Promedio del ratio de saldo disponible efectivo U1A	0.04	0.7%
44	porc_max_sldrsg_03m	Porcentaje máximo de saldo en productos RD U3M	0.03	0.6%
45	cnt_mespeornorrssff_12m	Cantidad de meses desde peor clasificación normal en SSFF	0.03	0.6%
46	rat_miemsup2r	Ratio de miembros del hogar mayores U2A	0.03	0.5%
47	var_ent_dist_rd_1a	Variabilidad del número de entidades con productos revolving U1A	0.02	0.4%
48	avg_decrsld12m	Promedio de decremento de saldo U12M	0.02	0.3%

La tabla con los descriptivos se puede encontrar en el archivo: "*Feature_Importance v2.xlsx*"

4.6 Dependencias parciales con valores SHAP

Los SHapley Additive exPlanations(SHAP) son una metodología innovadora creada para poder darle explicabilidad tanto local (utilizando LIME) como global, apoyándose de la teoría de juegos, a todo tipo de modelo, unificando varios métodos previos de tal forma que representa el único método posible de atribución de características aditivas consistente y localmente preciso. SHAP asigna a cada variable una medida de importancia en cada predicción que depende de cuánto impacta en la predicción esperada del modelo condicionado a dicha variable.

La tabla con los descriptivos se puede encontrar en el archivo: *"Graficas_Dependencia_Shaps_Final_v2.pdf"*

4.7 Especificaciones técnicas

A continuación se detalla el entorno tecnológico y las librerías utilizadas en el desarrollo del modelo.

Infraestructura y entorno de procesamiento:

Proceso	Herramienta
Creación y consulta de bases de datos	Amazon Athena (AWS)
Almacenamiento de datos en la nube	Archivos Parquet en Amazon S3 (AWS)
Modelamiento y desarrollo	JupyterHub sobre Amazon SageMaker (AWS)

Lenguaje y librerías (versionadas):

El desarrollo se realizó en Python, empleando las siguientes librerías con sus respectivas versiones:

Librería	Versión
pandas	2.3.3
numpy	2.0.2
scikit-learn	1.7.2
pyarrow	25.0.0
shap	0.49.1
matplotlib	3.10.9
catboost	1.2.10