



DOCUMENTO VALIDACIÓN

2026/07

Interbank – Validación Modelo PLAFT

En todas partes.
En todo momento.
Impulsando el crédito.

Historial de versiones

VERSIÓN	FECHA	REVISIÓN	COMENTARIOS
1.0	07/07/2026	André Gibert – Hugo Mansilla – Miguel Duarte	Versión inicial

INDICE

1.	INTRODUCCIÓN.....	5
2.	RESUMEN EJECUTIVO.....	7
3.	MODELO PLAFT.....	13
3.1.	Descripción de los modelos y sus resultados.....	13
3.2.	Documentación utilizada.....	15
3.3.	Ficheros utilizados.....	15
3.4.	Software utilizado.....	16
4.	REVISIÓN DOCUMENTACIÓN.....	17
4.1.	Descripción de las pruebas.....	17
4.2.	Resultados.....	17
4.3.	Conclusiones y aspectos críticos.....	22
5.	RÉPLICA Y DATA QUALITY.....	24
5.1.	Grado de adecuación de las bases de datos utilizadas.....	24
5.1.1.	Descripción de las pruebas.....	24
5.1.2.	Resultados.....	24
5.1.3.	Conclusiones y aspectos críticos.....	26
5.2.	Réplica del desarrollo del modelo.....	26
5.2.1.	Descripción de las pruebas.....	26
5.2.2.	Resultados.....	26
5.2.3.	Conclusiones y aspectos críticos.....	31
6.	VALIDACIÓN METODOLÓGICA.....	32
6.1.	Revisión de la metodología.....	32
6.1.1.	Descripción de las pruebas.....	32
6.1.2.	Resultados.....	32
6.1.3.	Conclusiones y aspectos críticos.....	36
7.	ANÁLISIS DE LAS VARIABLES.....	38

7.1.	Descripción de las pruebas.....	38
7.2.	Resultados.....	38
7.2.1.	Auditoría.....	38
7.2.2.	Importancia de las variables.....	38
7.2.3.	Missing.....	39
7.3.	Conclusiones y aspectos críticos.....	39
8.	RENDIMIENTO Y VALIDACIÓN.....	40
8.1.	Descripción de las pruebas.....	40
8.2.	Resultados.....	40
8.2.1.	Métricas de performance.....	40
8.2.2.	Conclusiones y aspectos críticos.....	41
9.	CONCLUSIONES Y SUGERENCIAS.....	42
10.	ANEXO.....	48
10.1.	Coeficiente de Gini.....	48
10.2.	Coeficiente de ROC.....	48

1. INTRODUCCIÓN

El presente informe detalla el proceso de validación independiente realizado sobre el modelo PLAFT, una herramienta analítica diseñada para optimizar alertas con riesgo de Lavado de Activos y Financiamiento del Terrorismo, reducir falsos positivos y mejorar la eficiencia operativa del equipo PLAFT. Este modelo tiene como objetivo principal estimar la probabilidad de que una alerta generada sea clasificada como “Alerta con Riesgo” luego del análisis realizado por un analista de investigación.

Desde una perspectiva técnica, el modelo se clasifica como Riesgo Tier 4 y está enfocado en el subsegmento Banca Pequeña Empresa (BPE) de Personas Jurídicas Minorista. El desarrollo se ha basado en un algoritmo de Machine Learning de tipo Boosting, seleccionando un conjunto final de 36 variables explicativas.

Como primera etapa de este desarrollo, Interbank ha definido el marco muestral y la variable objetivo del modelo, incluyendo en el desarrollo del modelo una muestra aleatoria de clientes sin alerta, asignándoles desempeño bueno (target = 0).

Debido a la naturaleza de la metodología utilizada, Interbank solicita la asesoría de Ubimia para la validación del modelo desarrollado, pensando siempre en las mejores prácticas, con resultados estables en el tiempo y considerando los riesgos más comunes de este tipo de modelos.

El proceso de validación de Ubimia consta de 3 fases, en cada una de las cuales se evalúan aspectos clave para garantizar la solidez del modelo antes de su implementación en producción.

1. **Revisión Documental:** Se analiza la completitud y coherencia de las bases de datos y documentación proporcionadas por Interbank, asegurando que la información entregada sea consistente y suficiente para el proceso de validación.
2. **Réplica y Data Quality:** Se replica el proceso de construcción del modelo con el objetivo de verificar que los resultados obtenidos coincidan con los documentados. Además, se evalúa la calidad de las bases de datos y las variables de origen, garantizando la fiabilidad de los insumos utilizados en el desarrollo del modelo.
3. **Revisión Metodológica:** Se lleva a cabo un análisis crítico, tanto cualitativo como cuantitativo, de la metodología aplicada en el desarrollo del modelo. El propósito es determinar si cumple con los mejores estándares y prácticas del sector.

En este documento se describen los resultados obtenidos, los diversos ámbitos evaluados, con una breve conclusión de los aspectos críticos a mejorar por cada ámbito y recomendaciones finales.

2. RESUMEN EJECUTIVO

Los resultados del presente informe se resumen en las siguientes tablas:

Ámbito	Prueba	Resumen resultados	Recomendaciones y observaciones	Alerta
Revisión documental	Ámbito objetivo	Se describe adecuadamente el objetivo del modelo, orientado a la estimación de la probabilidad de que una alerta sea clasificada como "con riesgo". La población objetivo presenta ambigüedad en su definición, en la primera definición no se menciona el porcentaje de muestra "sin alerta" que se incluye como falso positivo (target cero).	Se recomienda estandarizar la definición de la población objetivo en todo el documento para mayor coherencia.	
	Variable respuesta	El target del modelo corresponde a una clasificación binaria que representa si una alerta generada por el sistema de monitoreo es clasificada o no como "alerta con riesgo" por los analistas de investigación. Se evidencia una inconsistencia en la definición de la clase negativa, ya que posteriormente en el documento se menciona que se incorporan registros sin alertas como "falsos positivos". Se define un horizonte de evaluación de 30 días, sin embargo, no se describe qué significa dicho horizonte.	Se recomienda estandarizar la definición de la clase negativa en la variable respuesta en todo el documento para mayor coherencia. Además, se recomienda describir el significado del horizonte de evaluación para mayor claridad y entendimiento del problema.	
	Diccionario de datos	No se cuenta con un diccionario de variables formal. Sin embargo, se dispone de dos archivos que proporcionan información de las variables. Importancia_variables.csv : El documento presenta la información de las 36 variables descripción, predictoras del modelo. Contiene 4 columnas: nombre de la variable, importancia, valor absoluto SHAP y descripción. Hay 4 variables sin descripción. T_AGG_ALERTAS_PLAFT_Matriz_Equivalencia.xlsx : Este archivo contiene una tabla agregada de alertas plaft de aws. Contiene la información de 286 variables, se infiere que es el conjunto de variables previo al procesamiento y selección de variables finales.	Si bien se dispone de dos documentos que describen las variables del modelo, se recomienda elaborar un diccionario formal de variables que incluya, como mínimo, la siguiente información: Nombre de la variable, Descripción, Tipo de dato, Fuente de origen y Dominio o valores permitidos	
	Definición creación de la muestra	Se evidencia la definición del proceso de obtención de la muestra, incluyendo las fuentes de información integradas para la construcción de la base inicial y los filtros aplicados posteriormente. Sin embargo, el documento no detalla el tamaño de las muestras resultantes en cada etapa del proceso. Adicionalmente, se identifica una inconsistencia en la definición temporal de las muestras de desarrollo (train) y prueba (test). Inicialmente se indica que la muestra de prueba comienza en octubre; no obstante, los análisis posteriores se realizan utilizando información desde agosto. Una situación similar se observa en la muestra de desarrollo.	Se recomienda documentar el número de registros de cada muestra junto con su tasa de positivos. Adicionalmente, se recomienda corregir el período de las muestras de desarrollo y test.	
	Análisis estadísticos variables candidatas	Se evidencia la realización de análisis estadísticos de las variables en dos documentos (muestra de desarrollo y test), incluyendo estadísticos descriptivos (media, mediana, desviación estándar, percentiles, outliers, valores mínimos y máximos). El análisis descriptivo de las variables categóricas ('cod_ubigeo_cd', 'cod_sectorista_id', 'flg_alerta_12m', 'flg_vrcn_abonos_5m_1m' y 'flg_vrcn_efe_cargos_5m_1m') se realizó utilizando estadísticas de tendencia central y dispersión propias de variables numéricas. Dado que estas métricas poseen una interpretación limitada o nula para variables categóricas, se recomienda complementar el análisis mediante tablas de frecuencia, las cuales resultan más adecuadas para caracterizar este tipo de variables.	Se recomienda complementar el análisis de las variables categóricas mediante tablas de frecuencia.	
	Análisis de segmentación	No aplica segmentación, debido a que, de acuerdo con los códigos de desarrollo, la población corresponde a un subsegmento específico (BPE, o Banca Pequeña	Mencionar en el documento metodológico que la población corresponde a un subsegmento específico.	

		Empresa). Esto no se encuentra descrito en el documento metodológico.		
	Metodologías complementarias para variables	A nivel documental, no se dispone del detalle del proceso de creación y procesamiento de las variables.	Se recomienda documentar el proceso de creación y procesamiento de las variables.	
	Selección de variables	Se realizó un proceso de selección de variables que redujo 305 variables originales a 36 variables predictoras finales. Se eliminaron variables con bajo aporte informativo y altamente correlacionadas. No se documenta el detalle de la exclusión de variables, los criterios aplicados y las variables descartadas en cada etapa del proceso.	Se recomienda detallar el proceso de selección de variables.	
	Metodología de construcción del modelo	La documentación describe la metodología de construcción del modelo PLAFIT basado en XGBoost con su posterior calibración de probabilidades. Se detalla la elección de hiperparámetros, el objetivo de cada uno y la ejecución del proceso HPO. Si bien se describe las ventajas de la calibración del modelo, no se detallan las técnicas utilizadas ni la muestra. Además, respecto al balanceo de clases, se omiten aspectos relevantes (undersampling/oversampling).	Detallar las técnicas utilizadas del proceso de calibración y la muestra utilizada. Detallar tamaños de las clases antes y después del balanceo.	
	Metodología de validación	Se incluyen en el documento metodológico valores de Gini y AUC en período OOT. Sin embargo, no aparecen en el documento las métricas relevantes para validar este tipo de modelos, tales como precisión y recall top K, que sí se incluyen en los scripts de desarrollo.	Incluir en el documento metodológico métricas de validación que se calculan en el script de desarrollo, tales como precisión y recall top K.	
	Suficiencia documentación (completitud y coherencia)	La documentación presenta, de forma muy general, los aspectos más relevantes del proceso de desarrollo del modelo (obtención base inicial, filtros aplicados, definición bueno-malo, análisis temporal inicial, modelización, algoritmo utilizado, métricas y resultados). Sin embargo, se identifican diversos elementos que requieren ser mejorados y/o incorporados. Incluir: -Estandarización de la definición de población objetivo y target en todo el documento. -Significado del horizonte de evaluación. -Diccionario formal de variables. -Número de registros de cada muestra junto con su tasa de positivos. -Período de muestras de train y test corregido. -Mención del subsegmento considerado (BPE). -Creación y procesamiento de las variables. -Proceso de selección de variables. -Técnicas utilizadas del proceso de calibración y la muestra utilizada. -Tamaños de clases antes y después del balanceo. -Métricas de validación usadas en el desarrollo. Mejorar: Análisis estadístico, según el tipo de variable. Además, el documento metodológico no se alinea con los estándares de documentación de Interbank, por ejemplo, no tiene el logo, tipografía, colores corporativos, índice, control de versiones, anexos, bibliografía.	Revisar los hallazgos mencionados en las pruebas anteriores y alinear la documentación a los estándares de Interbank.	

Tabla 1 – Resumen ejecutivo resultados Revisión documental

Ámbito	Prueba	Resumen resultados	Recomendaciones y observaciones	Alerta
Réplica y Data Quality	Exactitud BBDD	Los números de registros no están en el documento metodológico para cada muestra, sin embargo, se pueden inferir de los resúmenes estadísticos y los códigos enviados. En ese sentido, los tamaños de las muestras de entrenamiento y validación coinciden. El tamaño de la muestra de test (1,509,824 registros) no coincide con el documentado en el archivo de 01_resumen_estadistico.csv correspondiente a la muestra de test (1,338,493 registros). La diferencia de registros coincide con los registros del mes 202512 de test, por lo que se infiere que el análisis que se describe en este último archivo CSV no incluye este mes.	Estandarizar los análisis con el mismo periodo de evaluación. En el caso de que por razones operativas no se pueda, documentar los análisis que se haya realizado con periodos distintos.	
	Unicidad BBDD	Se verifica que los registros de las muestras de validación y test son únicos a nivel de ID cliente y mes ('key_value', 'cod_mes'). Sin embargo, si se realiza el análisis a nivel de la variable cod_cli se encuentran duplicados, lo que parece indicar que el mismo cliente se puede repetir en un mes. Finalmente, no se tienen los ID de clientes para la muestra de train, por lo que no se puede validar la unicidad en esta muestra.	Aclarar si metodológicamente se pueden repetir los clientes en un mismo mes. Se deben incluir los id de los clientes en train para poder completar los análisis.	
	Construcción de la muestra	No fue posible replicar el proceso de construcción de la muestra, debido a que no se contó con los insumos necesarios para verificar los filtros aplicados durante su creación. En consecuencia, las bases de datos recibidas ya incorporaban dichos filtros, lo que constituye una limitación para el alcance del proceso de validación. Para la ejecución de las demás pruebas de réplica, se utilizó la muestra enviada.	Enviar los insumos para replicar la creación de la muestra.	
	Variable respuesta	No fue posible replicar el proceso de construcción de la variable respuesta, debido a que no se contó con los insumos necesarios para reproducir y validar su cálculo de manera independiente. En consecuencia, para las restantes pruebas de réplica, la variable respuesta fue considerada como un dato de entrada.	Enviar los insumos para replicar la variable respuesta.	
	Creación de variables	No se puede replicar el proceso de creación de variables, ya que no se dispone de los insumos necesarios.	Enviar los insumos para replicar la creación de variables.	
	Modelo	Debido a la utilización de entornos de desarrollo distintos, se observan ligeras diferencias en los resultados obtenidos durante el proceso de réplica del modelo. Se verifica que dichas diferencias no son materiales en el universo completo. Sin embargo, al aplicar el filtro de alertas automáticas sí se observan diferencias relevantes, como se detalla en la prueba "Indicadores de Eficiencia" en este mismo ámbito. Respecto al objeto del modelo entrenado, este no coincide con la documentación. Esto se debe probablemente a que el objeto y/o la documentación están desactualizados.	Se debe: -Resolver las diferencias en los resultados del segmento de alertas automáticas. -Verificar que la documentación del modelo coincida el objeto del modelo oficial que será utilizado en producción.	
	Importancia/Peso de las variables	Existen algunas diferencias mínimas en el orden de importancia de las variables debido a que el modelo replicado no es exactamente el mismo por la diferencia del entorno de desarrollo ejecutado. Sin embargo, las diferencias están dadas por valores mínimos y no se considera relevante.	No hay recomendación.	
	Indicadores de eficiencia	Se observan diferencias relevantes entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601 para el universo de alertas automáticas.	Analizar el motivo que explique las diferencias de AUC y Gini en los meses de 202512 y 202601 para el universo de alertas automáticas.	

Tabla 2 – Resumen ejecutivo resultados Réplica y Data Quality

Ámbito	Prueba	Resumen resultados	Recomendaciones y observaciones	Alerta
Metodología	Definición variable respuesta	La variable respuesta se define a partir de la clasificación realizada por los analistas, distinguiendo entre alertas catalogadas como "Con Riesgo" y "Falso Positivo". En consecuencia, el modelo busca aproximar el criterio utilizado por los analistas PLAFT para evaluar las alertas generadas por los sistemas de monitoreo, actuando como un proxy del fenómeno de lavado de activos y financiamiento del terrorismo. Considerando que el desarrollo de modelos PLAFT se encuentra aún en una etapa relativamente incipiente, este enfoque se considera razonable. No obstante, debe tenerse presente que la clasificación de una misma alerta podría variar entre distintos analistas ante antecedentes similares, lo que introduce una fuente potencial de variabilidad en la variable objetivo. Este riesgo es inherente a los modelos basados en juicios expertos y constituye un desafío conocido en este ámbito (Berquist, 2024). Por otra parte, en la medida en que se disponga de información histórica suficiente y de una definición más directa del evento de interés, se recomienda evaluar el desarrollo de modelos orientados a explicar directamente el fenómeno PLAFT, reduciendo así la dependencia del criterio subjetivo de los analistas.	Se recomienda: -Indicar en la documentación cómo se mitigará el riesgo que la misma alerta sea calificada como positiva por un analista y negativa por otro analista. -Avanzar hacia un enfoque donde se modele directamente el fenómeno PLAFT.	
	Metodología de selección de muestra	Debido a la baja prevalencia de alertas con riesgo, se considera correcto usar todo el universo de casos positivos. Asimismo, se valora positivamente que la muestra esté compuesta de tres grupos: (1) alertas calificadas como con riesgo, (2) alertas calificadas como falsos positivos, (3) una muestra pequeña (0.5%) del universo de clientes sin alerta, pues mitiga parcialmente el sesgo de entrenar un modelo solo con los dos primeros grupos. Sin embargo, la proporción de clientes sin alerta elegida no está justificada y podría ser considerada como una decisión sin sustento metodológico. Cabe destacar que la conveniencia de incluir clientes sin alerta depende directamente del objetivo del modelo. Si el propósito es identificar qué clientes deberían ser investigados por el sistema de monitoreo, la incorporación de clientes sin alerta resulta conceptualmente adecuada. En cambio, si el objetivo es evaluar la capacidad discriminatoria del sistema de alertas automáticas entre alertas con y sin riesgo, la inclusión de clientes sin alerta podría no ser consistente con la población objetivo del problema.	Probar distintas combinaciones de proporciones de clientes sin alerta dentro de la muestra de desarrollo, para identificar cuál de ellas entrega mejores métricas y de este modo justificar la elección de la proporción óptima usando un criterio cuantitativo más defendible.	
	Segmentación	No aplica, ya que se está trabajando en un subsegmento específico (BPE), más aun teniendo en cuenta la baja materialidad de casos positivos.	No hay recomendación.	

	Metodología selección de variables	El conjunto de variables seleccionadas para el modelo es adecuado, recogiendo información de distintos ámbitos, tales como: transaccionales, sociodemográficas, ratios financieros, comportamiento histórico AML, KYC, comercio exterior. Sin embargo, no hay una descripción detallada del proceso que permite reducir el conjunto original de 305 variables a las 36 finales. Como referencia, en el script "<i>0.limpieza_datos.ipynb</i>" se describe un proceso de selección de variables a partir de un conjunto inicial de 187 variables, usando los siguientes criterios: -Valores únicos (constantes). -% de valores nulos superior a un umbral determinado (20%). -Correlación de Pearson y Spearman superior a umbrales determinados (90% y 90%, respectivamente). Estos criterios se consideran adecuados, pero los umbrales usados deberían justificarse. Además, se evidencia que no es la versión final del script usado para seleccionar las variables del modelo, pues se obtienen 28 variables explicativas, mientras que el modelo validado tiene 36 en total. Por lo tanto, es necesario documentar cuál es la relación de esta versión del script con la selección de variables finales del modelo.	Se recomienda incluir en documento metodológico el proceso de selección descrito en el script "<i>0.limpieza_datos.ipynb</i>", pero usando la versión final que permita llegar al universo de 36 variables del modelo validado. Asimismo, justificar los umbrales usados en los criterios de % de valores nulos y de correlaciones, y aclarar si los criterios y umbrales mencionados son los mismos que se usan para la selección final de variables.	
	Proceso de desarrollo de los modelos	El modelo desarrollado permite priorizar alertas generalizando el criterio usado por los analistas de investigación para identificar los casos con riesgo. Sin embargo, los siguientes hallazgos requieren atención inmediata: 1. No queda claro que las ventanas temporales del target y las variables explicativas sean disjuntas, si hay traslape temporal el modelo podría no ser aplicable porque "predice con el futuro". 2. No hay una separación explícita de clientes entre los conjuntos de train-test y validación. De hecho, se verifica que existen clientes presentes tanto en test como en validación. Debido a que la ventana temporal de entrenamiento más validación es relativamente corta (15 meses), existe un riesgo real de que las observaciones del mismo cliente en conjuntos distintos no sean independientes. 3. La calibración del modelo se hace sobre el mismo conjunto de validación, debería ser distinto.	Revisar las fuentes de datos de origen del modelo, para garantizar que las variables explicativas contienen información de períodos anteriores al de predicción. En el proceso de construcción de las muestras de train, test y validación, se recomienda asegurar que un mismo cliente no esté presente en más de uno de estos conjuntos. En caso de que existan clientes compartidos entre las muestras, se recomienda documentar y justificar dicha situación, evaluando su potencial impacto sobre los resultados del modelo. Usar un conjunto que sea independiente al de validación para calibrar el modelo.	
	Revisión de hiperparámetros seleccionados	El espacio de búsqueda usado para el desarrollo es adecuado. En particular, el hiperparámetro <code>scale_pos_weight=494</code> indica que los casos positivos son ponderados para balancear la muestra al momento de entrenar el modelo, aunque esta ya viene balanceada previamente. Además, no se usan parámetros de regularización como <code>lambda</code> y <code>alpha</code>, que permiten reducir el overfitting y obtener predicciones más estables.	Se recomienda complementar la documentación metodológica con una justificación del uso del hiperparámetro <code>scale_pos_weight</code>, considerando que previamente se realizó un proceso de balanceo de la muestra. Asimismo, se sugiere documentar los criterios que sustentan la decisión de no incorporar mecanismos de regularización durante el entrenamiento del modelo.	
	Metodología de performance	La metodología utilizada para medir el desempeño del modelo se considera adecuada, pero no suficiente. El uso de la precisión y el recall top K es necesario para medir cuál es el beneficio de la priorización de alertas. A diferencia de otros modelos predictivos con variable de respuesta binaria, las métricas habituales tales como el Gini o el KS no bastan por sí solas para medir el desempeño adecuadamente con la tipología del modelo validado.	Utilizar métricas complementarias para medir la eficiencia del modelo. Por ejemplo, se sugiere utilizar Lift para este tipo de problemas.	

	Auditoría de datos	Todas las observaciones o dudas fueron contestadas de manera oportuna por los dueños del modelo. No se encuentran observaciones relevantes en cuanto a las distribuciones de las variables del modelo.	No hay recomendación.	
	Análisis de missing	Las variables categóricas fueron completadas con el valor "SIN_INFO", lo cual se considera adecuado. Sin embargo, las variables numéricas se rellenan con ceros, lo cual es inadecuado para variables de variaciones, ratios y antigüedad del cliente. En estos casos, las variables deben ser imputadas de acuerdo con el significado de la variable y del valor missing. Debido a que los conjuntos de datos vienen con las imputaciones ya aplicadas, no es posible cuantificar cuál es el impacto de esto.	Cuantificar en la etapa de preprocesamiento el % de missings, justo después de ejecutar la query de extracción de datos desde AWS Athena. En el caso de las variables numéricas, definir estrategias de imputación adecuadas, dependiendo del significado de la variable y del valor missing.	
	Importancia/Peso de las variables	Ninguna variable sobrepasa el umbral superior del 20% de importancia, definido en el Manual de Indicadores y Umbrales de Interbank. Sin embargo, hay cuatro variables por debajo del umbral inferior del 0.1% definido en el mismo manual (flg_alerta_12m, avg_cp_men_ing_12m, share_cp_ingresos, flg_vrcn_efe_cargos_5m_1m).	Considerar la eliminación de las cuatro variables con menos de 0.1% de importancia.	

Tabla 3 – Resumen ejecutivo resultados Metodología

Ámbito	Prueba	Resumen resultados	Recomendaciones y observaciones	Alerta
Performance	Indicadores de predicción/precisión	Para entrenar el modelo, la documentación indica que se usa como métrica de optimización el AUC, obteniendo como resultado 0.99040 en train y 0.95853 en validación dentro de la muestra, con una diferencia entre ambas equivalente a 6.4 puntos de Gini, lo cual indica que hay un ligero sobreajuste, pero que se considera aceptable debido a la baja materialidad de casos positivos. Se observa en el script de optimización de hiperparámetros con HPO que el AUC del score raw y calibrado en la muestra de validación es 0.9995 , lo cual es consistente con la baja materialidad de positivos. No se reporta esta métrica sobre el universo de alertas automáticas, para poder tener una referencia del poder predictivo del modelo ante un escenario productivo, lo cual es una omisión relevante. Además, el AUC se considera una métrica inadecuada para definir si el modelo tiene buenos niveles de predicción en su entrenamiento. Para poder determinar esto, deberían incluirse métricas tales como precisión y recall top K, como se hizo en la muestra de test.	Incluir los resultados de precisión y recall top K en las muestras de train y validación, al momento de entrenar el modelo. Asimismo, las métricas deberían ser reportadas en el universo de alertas automáticas. Idealmente, en la optimización de hiperparámetros reemplazar el AUC como eval_metric por la precisión.	
	Muestra de validación	Los rangos de valores de precisión y recall top K, para distintos valores de K (=100, 200, 500, 1000, 2000) se consideran adecuados. En particular, la precisión top 100 varía entre 7% y 18%. Cabe señalar que, para efectos de seguimiento del modelo, la apertura por mes no es recomendable debido a la baja materialidad de casos positivos, que genera una alta volatilidad de las métricas en términos relativos.	Medir el desempeño del modelo a nivel más agregado (p. ej. trimestral), para que haya mayor materialidad de casos positivos.	

Tabla 4 – Resumen ejecutivo resultados Performance

3. MODELO PLAFT

En el siguiente apartado se hace una breve descripción del modelo validado junto con sus resultados, así como también una descripción de los insumos recibidos para el ejercicio de validación (documentos y ficheros) y el software utilizado para el desarrollo.

3.1. Descripción de los modelos y sus resultados

Población objetivo

Clientes de Interbank clasificados como Personas Jurídicas Minorista (subsegmento BPE) con alertas levantadas por el Sistema de Monitoreo.

Períodos modelización

Los períodos utilizados para construir la muestra de desarrollo son los siguientes:

- Muestra de desarrollo: enero 2025 – julio 2025.
- Muestra de validación dentro de la muestra: enero 2025 – julio 2025.
- Muestra de validación fuera de tiempo (out-of-time, uOOT): agosto 2025 – abril 2026.

Variable respuesta

La variable respuesta (*target*) es una variable categórica binaria que representa si una alerta generada por el sistema de monitoreo sea clasificada como “Alerta con Riesgo” luego del análisis realizado por un analista de investigación. Se define con 1 para las alertas clasificadas como “Con Riesgo” y 0 para las alertas clasificadas como “Falso positivo” junto con una muestra controlada de registros sin alertas (*target* nulo), representando el 10% de dichos casos. Posteriormente se realiza un balanceo de clases sobre la muestra de entrenamiento, donde la estrategia aplicada fue conservar el 100% de los casos positivos, ajustar la cantidad de casos negativos mediante técnicas de resampling manteniendo una distribución aproximada de 99.5% para la clase negativa y 0.5% para la clase positiva. Cuando la cantidad de registros negativos era insuficiente, se aplicó oversampling con reemplazo; en caso contrario, se utilizó undersampling.

Metodología de modelización

En términos generales, la metodología de modelización empleada corresponde a Extreme Gradient Boosting (XGBoost), técnica de aprendizaje supervisado basada en árboles de decisión.

Resultados

Para evaluar la performance del modelo, se incluyen los indicadores AUC y Gini sobre la muestra completa y filtrada sobre alertas operativas. Adicionalmente, en el desarrollo se calcula precisión (Precision) y sensibilidad (Recall) en los segmentos de mayor riesgo o Top K, pero no forman parte de las métricas oficiales documentadas.

El indicador Gini en las muestras de validación y test es el siguiente.

Métrica	Documentado
Gini	91,572

Tabla 5 – Resultados Gini sobre muestra de validación – Universo total

Mes	Gini
202508	93.43
202509	87.81
202510	85.91
202511	88.76
202512	90.39
202601	94.50
202602	91.83

202603	89.72
202604	95.91

Tabla 6 – Resultados Gini mensual sobre muestra de test – Universo total

Mes	Gini
202508	42.02
202509	60.66
202510	64.70
202511	44.12
202512	52.90
202601	47.08
202602	55.44
202603	32.76
202604	46.40

Tabla 7 – Resultados Gini mensual sobre muestra de test – Solo alertas automáticas

3.2. Documentación utilizada

La siguiente tabla recoge la documentación facilitada por Interbank para realizar el proceso de validación:

Insumo / Archivo	Descripción
Documento_Metodologico_PLAFT_PJ_Minorista_v2.pdf	Segunda versión del documento metodológico del modelo PLAFT, se describe la construcción, validación e implementación del modelo.
importancia_variables.csv	Archivo csv que contiene el nombre, la importancia, el valor absoluto y la descripción de las 36 variables finales utilizadas en el modelamiento.

Tabla 8 – Documentación facilitada por Interbank

3.3. Ficheros utilizados

Se reciben los ficheros (inputs) para poder realizar la lectura y correcta réplica de los modelos. Las bases de datos enviadas por Interbank para el proceso de validación son las siguientes:

NOMBRE DE ARCHIVO	DESCRIPCIÓN
-------------------	-------------

headers_total.csv	Base de datos que contiene dos columnas. La primera columna contiene los nombres de las variables predictoras y el target. La segunda columna contiene el tipo de dato de cada variable.
train_total.csv	Base de datos correspondiente a la muestra de entrenamiento, obtenida mediante una partición aleatoria del 67% de la base de desarrollo. Contiene las variables predictoras del modelo y la variable respuesta.
validation_total.csv	Base de datos correspondiente a la muestra de validación, obtenida mediante una partición aleatoria del 33% de la base de desarrollo. Contiene las variables predictoras del modelo y la variable respuesta.
test_total.csv	Base de datos correspondiente a la muestra de test (oot). Contiene las variables predictoras del modelo y la variable respuesta.
extras_validation_total.csv	Base de datos auxiliar correspondiente al conjunto de validación. Contiene variables no utilizadas en el entrenamiento del modelo, pero necesarias para la identificación de registros.
extras_test_total.csv	Base de datos auxiliar correspondiente al conjunto de test. Contiene variables no utilizadas en el entrenamiento del modelo, pero necesarias para la identificación de registros.

Tabla 9 – Archivos facilitados por Interbank

3.4. Software utilizado

Los softwares utilizados fueron los siguientes:

- Creación de bases: Athena – AWS
- Almacenamiento de bases en la nube: Archivos parquet en S3 – AWS
- Modelamiento: Jupyter Hub en Sagemaker – AWS

4. REVISIÓN DOCUMENTACIÓN

En este apartado se describen las diversas pruebas y resultados obtenidos en la fase de revisión documental, la cual tiene por objetivo realizar una revisión a la documentación enviada por Interbank y analizar si esta cumple con los estándares para ser presentada al órgano supervisor.

4.1. Descripción de las pruebas

En base a la información puesta a disposición por parte de Interbank, se revisa que la documentación cuente con los siguientes elementos:

1. Objetivo, ámbito y muestra de desarrollo:
 - Definición del objetivo del modelo.
 - Descripción del ámbito de aplicación del modelo.
 - Descripción del conjunto de desarrollo y filtros aplicados.
 - Aplicación de técnicas de análisis estadístico.
 - Tratamiento de variables.
 - Selección de variables para el modelo.
 - Muestra utilizada para el desarrollo del modelo: criterio de selección, filtros aplicados y tamaño de la muestra.
 - Comprobación de la existencia de un control de versiones y de la actualización del manual donde se describe el proceso de construcción. Se debe reflejar la fecha de la nueva versión, los cambios realizados y el nombre de la persona responsable de los cambios.
2. Metodología de desarrollo del modelo: se pretende comprobar que se encuentra correctamente documentada la metodología utilizada y que esta sea pertinente a la información disponible.
3. Metodología de validación: se pretende comprobar que está documentada la metodología utilizada para validar el modelo desarrollado.
4. Resultados del modelo: se revisa que la documentación contenga los resultados del modelo, tanto las variables finales utilizadas y los indicadores del modelo.
5. Revisión de la documentación: se revisa que la documentación cumple con los estándares necesarios para un proceso de réplica.

4.2. Resultados

Interbank cuenta con un documento que permite entender el proceso de principio a fin. Se logró la réplica completa del modelo a partir de los datos de input entregados, con diferencias inmatrimiales con respecto a los resultados presentados en el documento metodológico.

Objetivo, ámbito, muestra de desarrollo y modelo de calificación

En el documento se especifica lo siguiente:

1. Introducción
 - 1.1. Ámbito de aplicación
 - 1.2. Periodo de aplicación
 - 1.3. Objetivo del Modelo
 - 1.4. Resumen del modelo
2. Descripción general
 - 2.1. Diseño del experimento
 - 2.2. Etapas de construcción del modelo de Machine Learning
3. Descripción detallada de procesos
 - 3.1. Obtención de la base inicial
 - 3.2. Filtros aplicados sobre las bases iniciales
 - 3.3. Indicador Bueno – Malo
 - 3.4. Análisis temporal inicial
 - 3.5. Análisis descriptivo inicial
 - 3.6. Modelización
 - 3.6.1. Selección de variables
 - 3.6.2. Análisis Bivariante
4. Algoritmo XGBoost
 - 4.1. Hiperparámetros
 - 4.2. Dependencias parciales y SHAP
5. Métricas
6. Resultados
 - 6.1. Tablas de eficiencia

Se describe el objetivo del modelo, así como su enfoque metodológico. Asimismo, se detallan las etapas de desarrollo, incluyendo el diseño del modelo, la construcción y análisis de las

variables explicativas y de la variable objetivo (target), junto con la metodología de modelamiento, entrenamiento y evaluación.

Se define adecuadamente el objetivo del modelo, así como su uso dentro de los procesos de evaluación. La población objetivo está bien definida, sin embargo, presenta cierta ambigüedad en la documentación. Al principio se menciona que la población objetivo son “Clientes PJ Minorista con generación de alertas dentro del sistema de monitoreo”, sin embargo, posteriormente se menciona la inclusión como falso positivo de un porcentaje de muestra “sin alerta”. Adicionalmente, se identifica que la población corresponde a un subsegmento específico (BPE o Banca Pequeña Empresa), sin embargo, esto no está descrito en el documento.

En cuanto a la definición y construcción de la muestra, el procedimiento se realiza del siguiente modo:

1. Se selecciona el universo de clientes del subsegmento BPE de la base de alertas de los meses entre ene-2025 y mar-2026.
2. Se separa el universo anterior en clientes antiguos (correspondientes a los meses entre ene-2025 y jul-2025) y recientes (ago-2025 a mar-2026). Estos últimos son reservados como conjunto de test (OOT).
3. Del universo de clientes antiguos con alertas, se seleccionan todos los casos positivos (=marcados “Con Riesgo” por analistas de investigación) disponibles y de los casos negativos se elige una muestra aleatoria, de tal modo que las proporciones sean 0.5% y 99.5%, respectivamente.
4. Al conjunto obtenido en el paso anterior, se le suma un 0.5% del universo de clientes antiguos sin alertas.

El documento describe las principales fuentes de información utilizadas: información transaccional, financiera, historial de alertas, datos geográficos y actividad económica, así como los filtros generales aplicados sobre la base inicial, considerando clientes activos, pertenecientes al segmento Persona Jurídica Minorista, la eliminación de registros incompletos críticos y la consolidación de la información a nivel cliente. Además, se especifica una partición temporal para los conjuntos de entrenamiento, validación y prueba, con el propósito de evitar fuga de información. No obstante, la documentación presenta algunas inconsistencias y omisiones que limitan la trazabilidad del proceso de construcción de la muestra. No queda completamente documentada la secuencia mediante la cual se generan las

muestras de entrenamiento y validación, se logra identificar a través de los notebooks, pero adicionalmente debe estar documentada la división temporal de la muestra de desarrollo. No se encuentra documentado el tamaño de las muestras de entrenamiento, validación y test, además, el documento presenta diferencias entre distintas secciones respecto de los períodos considerados para validación y test, inicialmente se indica que la muestra de test comienza en octubre, no obstante, los análisis posteriores se realizan utilizando información desde agosto. Esto dificulta identificar con precisión el universo utilizado en cada etapa del desarrollo a partir de la documentación. Finalmente, durante la réplica se observó la aplicación de filtros adicionales que no se encuentran descritos en el documento metodológico, por lo que sería recomendable incorporarlos para fortalecer la reproducibilidad del proceso.

En relación con la definición de la variable respuesta, esta se establece como una variable binaria, donde el valor 1 corresponde a una alerta clasificada como "Con Riesgo" y el valor 0 a una alerta clasificada como "Falso Positivo" o a registros que no generan alerta. La documentación describe de manera general el criterio utilizado para su construcción, indicando que se conservaron las etiquetas originales de las alertas clasificadas y que se incorporó una muestra controlada de registros sin alerta, cuyos valores fueron imputados como clase negativa, con el objetivo de mejorar la representación de casos no riesgosos. No obstante, la metodología presenta oportunidades de mejora en cuanto al nivel de detalle del proceso de construcción del target. En particular, no se documenta con precisión el horizonte temporal utilizado para asociar las variables explicativas con la ocurrencia del evento objetivo, ni queda completamente descrita la lógica mediante la cual se identifican y seleccionan los registros sin alerta incorporados como clase negativa. Asimismo, la inclusión de una muestra de clientes sin alerta modifica la definición inicial de la población objetivo, por lo que sería conveniente explicitar la justificación metodológica de esta decisión y su impacto sobre la construcción de la variable respuesta.

Respecto del análisis estadístico y selección de variables, se documenta un proceso de análisis descriptivo inicial, seguido por una etapa de depuración y preprocesamiento de las variables. El análisis estadístico incluyó estadísticos descriptivos como la media, mediana, desviación estándar, percentiles, outliers, valores mínimos y máximos. Para las variables categóricas `'cod_ubigeo_cd'`, `'cod_sectorista_id'`, `'flg_alerta_12m'`, `'flg_vrcn_abonos_5m_1m'` y `'flg_vrcn_efe_cargos_5m_1m'` se utilizaron medidas estadísticas de tendencia central y dispersión propias de variables numéricas. Dado que estas métricas poseen una interpretación limitada o nula para variables categóricas, se recomienda

complementar el análisis mediante tablas de frecuencia, las cuales resultan más adecuadas para caracterizar este tipo de variables. La metodología de selección de variables describe la eliminación de variables identificadoras y de control, el tratamiento de valores faltantes, la imputación de datos, el reagrupamiento de variables categóricas, la transformación de variables temporales y la eliminación de variables altamente correlacionadas. Asimismo, se indica que el conjunto inicial de 305 variables fue reducido hasta obtener el conjunto final de 36 variables utilizado para el entrenamiento del modelo. Sin embargo, la documentación no describe de manera suficientemente detallada el proceso que permite reproducir la selección de variables. En particular, no se especifica cómo se reduce el universo inicial de 305 variables al conjunto final, ni se justifica la elección de los umbrales utilizados para eliminar variables con alta proporción de valores faltantes o alta correlación. Adicionalmente, se identifican inconsistencias en el número de variables finales reportadas, ya que en distintas secciones del documento se indica que el modelo utiliza 36 y 56 variables, respectivamente.

Respecto de la metodología de construcción del modelo, la documentación describe las principales etapas del entrenamiento de un modelo de clasificación supervisada basado en XGBoost, incluyendo la optimización automática de hiperparámetros mediante Amazon SageMaker Hyperparameter Optimization (HPO), la configuración del algoritmo y el proceso de calibración posterior de las probabilidades generadas por el modelo. Asimismo, se presentan los hiperparámetros finales seleccionados y se describe el objetivo de los principales parámetros utilizados durante el entrenamiento. No obstante, la documentación presenta oportunidades de mejora en el nivel de detalle de algunos procesos metodológicos relevantes. En particular, si bien se describe el objetivo y los beneficios de la calibración de probabilidades, no se especifica la técnica empleada (por ejemplo, Platt Scaling o Isotonic Regression), ni el conjunto de datos utilizado para realizar dicha calibración. De igual forma, aunque se indica que se aplicó una estrategia de balanceo de clases mediante técnicas de resampling, no se documentan aspectos relevantes de su implementación, como el detalle para utilizar undersampling u oversampling, ni el procedimiento seguido para obtener la distribución final de las clases. La incorporación de estos antecedentes fortalecería la trazabilidad y reproducibilidad del proceso de desarrollo del modelo.

En relación con la metodología de validación y evaluación de performance, se reportan las principales métricas discriminatorias del modelo, incluyendo AUC y Gini, tanto para el conjunto de validación como para los períodos fuera de muestra (OOT), además de un análisis específico sobre el subconjunto de alertas operativas donde el modelo será utilizado. Sin embargo, el

documento no presenta indicadores como precisión (Precision) y sensibilidad (Recall) en los segmentos de mayor riesgo o Top K, métricas especialmente relevantes en modelos de priorización de alertas, las cuales sí fueron identificadas en los scripts de desarrollo.

Finalmente, en cuanto al control de versiones, se identifican los softwares utilizados en el desarrollo del modelo; sin embargo, no se detallan las versiones específicas ni las librerías y dependencias empleadas, lo que limita la replicabilidad técnica del proceso.

4.3. Conclusiones y aspectos críticos

En términos generales, la documentación presenta los aspectos más relevantes del proceso de desarrollo del modelo: obtención base inicial, filtros principales aplicados, definición target, análisis temporal inicial, modelización, algoritmo utilizado, métricas y resultados. Sin embargo, se identifican aspectos de mejora los cuales se han clasificado según su prioridad.

Donde:

- Prioridad Alta: se debe corregir la indicación con urgencia.
- Prioridad media: se debe corregir la indicación, no es un factor inhabilitante.
- Prioridad baja: se sugiere corregir la indicación para mejorar la calidad de la documentación.

Se requieren más detalles en los siguientes puntos:

1. El documento metodológico no se alinea con los estándares de documentación de Interbank, por ejemplo, no tiene el logo, tipografía, colores corporativos, índice, control de versiones, anexos, bibliografía. Para mitigar esta alerta, se recomienda alinear la documentación a los estándares de Interbank. (*Alerta media*)
2. La población objetivo presenta ambigüedad en su definición. Para mitigar esta alerta, se recomienda estandarizar la definición de la población objetivo en todo el documento para mayor coherencia. (*Alerta baja*)
3. Se define un horizonte de evaluación de 30 días, sin embargo, no se describe qué significa dicho horizonte. Para mitigar esta alerta, se recomienda describir el significado del horizonte de evaluación para mayor claridad y entendimiento del problema. (*Alerta baja*)
4. No se cuenta con un diccionario de variables formal. Para mitigar esta alerta, se recomienda elaborar un diccionario formal de variables. (*Alerta baja*)

5. El documento no detalla el tamaño de las muestras resultantes en cada etapa del proceso. Adicionalmente, se identifica una inconsistencia en la definición temporal de las muestras de desarrollo (train) y prueba (test). Para mitigar esta alerta, se recomienda documentar el número de registros de cada muestra junto con su tasa de positivos y corregir el periodo de las muestras de desarrollo y test. *(Alerta baja)*
6. La población corresponde a un subsegmento específico (BPE, o Banca Pequeña Empresa). Esto no se encuentra descrito en el documento metodológico. Para mitigar esta alerta, se recomienda mencionar en el documento metodológico que la población corresponde al subsegmento específico de BPE. *(Alerta baja)*
7. A nivel documental, no se dispone del detalle del proceso de creación y procesamiento de las variables. Para mitigar esta alerta, se recomienda documentar el proceso de creación y procesamiento de las variables. *(Alerta baja)*
8. No se documenta el detalle de la exclusión de variables, los criterios aplicados y las variables descartadas en cada etapa del proceso. Para mitigar esta alerta, se recomienda detallar el proceso de selección de variables. *(Alerta baja)*
9. Si bien se describe las ventajas de la calibración del modelo, no se detallan las técnicas utilizadas ni la muestra. Además, respecto al balanceo de clases, se omiten aspectos relevantes. Para mitigar esta alerta, se recomienda detallar las técnicas utilizadas del proceso de calibración y la muestra utilizada y los tamaños de las clases antes y después del balanceo. *(Alerta baja)*
10. No aparecen en el documento las métricas relevantes para validar este tipo de modelos, tales como precisión y recall top K, que sí se incluyen en los scripts de desarrollo. Para mitigar esta alerta, se recomienda incluir en el documento metodológico métricas de validación que se usan en el desarrollo, tales como precisión y recall top K. *(Alerta baja)*

5. RÉPLICA Y DATA QUALITY

En el siguiente apartado se muestran los resultados obtenidos en el proceso de Réplica y Data Quality.

5.1. Grado de adecuación de las bases de datos utilizadas

En este ámbito se valida el grado de adecuación de las bases de datos y variables de origen utilizadas en la construcción de los modelos y su nivel de documentación.

5.1.1. Descripción de las pruebas

Se han revisado las BBDD utilizadas en la construcción de la muestra, los modelos y la documentación puesta a disposición por Interbank, con el objeto de verificar que la estructura de las BBDD incluya todos los campos necesarios para la construcción del modelo:

- El estudio de la **exactitud** de la información manejada.
- Estudio de **duplicidades** en los registros contenidos.

5.1.2. Resultados

Los resultados de las pruebas realizadas son los siguientes:

La BBDD utilizada cuenta con las variables necesarias para replicar la metodología de desarrollo del modelo final y llevar a cabo una validación parcial de ésta. Adicionalmente se verificó lo siguiente:

Exactitud: No es posible replicar los filtros, ya que la base de datos recibida ya los tiene aplicados. El número de registros de cada muestra no están en el documento metodológico, sin embargo, se pueden inferir de los resúmenes estadísticos y los códigos enviados. En ese sentido, los tamaños de las muestras de entrenamiento y validación coinciden. El tamaño de la muestra de test (1,509,824 registros) no coincide con el documentado en el archivo 01_resumen_estadistico.csv correspondiente a la muestra de test (1,338,493 registros). La diferencia de registros coincide con los registros del mes 202512 de test, por lo que se infiere que el análisis que se describe en este último archivo CSV no incluye este mes.

- **Unicidad:** Para las muestras de validación y test, se presenta la variable *key_value*. Se realizó una prueba de duplicidad de estas bases, donde se encontró lo siguiente:

Registros con key_value repetido	14,864
----------------------------------	--------

Cantidad de key_value repetidos	7,097
Valores únicos de key_value	49,983
% de registros con key_value repetido	25.74
Total de registros	57,750

Tabla 10 – Resumen duplicados usando variable key_value – Muestra de validación

Registros con key_value repetido	1,501,933
Cantidad de key_value repetidos	191,436
Valores únicos de key_value	199,327
Porcentaje de valores únicos	99.48
Total registros	1,509,824

Tabla 11 – Resumen duplicados usando variable key_value – Muestra de test

A partir de las tablas anteriores, se observa la presencia de duplicados en la variable *key_value*. No obstante, se verificó que los duplicados también estén presentes en diferentes meses, donde se observa que no hay duplicados a nivel *key_value* y *cod_mes*:

Registros con key_value-cod_mes repetido	0
Cantidad de llaves key_value - cod_mes repetidas	0
Cantidad de llaves únicas key_value - cod_mes	57,750
% de registros con llave repetida	0
Total de registros	57,750

Tabla 12 – Resumen duplicados usando variables key_value y cod_mes – Muestra de validación

Registros con key_value-cod_mes repetido	0
Cantidad de llaves key_value - cod_mes repetidas	0
Cantidad de llaves únicas key_value - cod_mes	1,509,824
% de registros con llave repetida	0
Total de registros	1,509,824

Tabla 13 – Resumen duplicados usando variables `key_value` y `cod_mes` – Muestra de test

Para la base de entrenamiento, no se cuenta con la base de datos de variables auxiliares *extras_train_total.csv*, por lo que no se puede validar la unicidad de la muestra.

5.1.3. Conclusiones y aspectos críticos

En general, las bases de datos cumplen con los criterios analizados. Sin embargo, debe detallarse con mayor precisión los tamaños y periodos de los conjuntos de datos utilizados en cada etapa del proceso de modelamiento. Respecto a la unicidad de los datos, se verifica que las bases de validación y test no contienen duplicados a nivel *key_value* y *cod_mes*. No se puede verificar para la muestra de entrenamiento, por lo que se recomienda entregar los insumos necesarios para dicha prueba.

5.2. Réplica del desarrollo del modelo

En base a la documentación del modelo y muestra de desarrollo puesta a disposición, se han realizado las réplicas en el proceso de desarrollo del modelo. El objetivo es verificar que la entidad dispone de una documentación detallada y actualizada de la metodología de forma que un tercero pueda comprender y replicar los cálculos.

5.2.1. Descripción de las pruebas

Se replica:

- Variable respuesta utilizada
- Construcción de la muestra
- Creación de variables
- Modelo
- Indicadores de eficiencia
- Importancia de variables

5.2.2. Resultados

5.2.2.1. Construcción de la muestra

La documentación especifica las ventanas de tiempo utilizadas para las muestras de desarrollo y de test out-of-time (OOT). No obstante, no se dispone de los insumos necesarios para replicar íntegramente las etapas de construcción de la muestra en lo referente a los filtros aplicados, dado que, las bases de datos ya incorporan dichos filtros.

Los resultados obtenidos de las muestras enviadas por el cliente y la información documentada y/o extraída de los insumos del cliente son los siguientes:

Muestra	Periodo	Documentado	Réplica con base recibida
Train	2025-01 a 2025-07	117,250	117,250
Validación	2025-01 a 2025-07	57,750	57,750
Test (OOT)	2025-08 a 2026-04	1,338,493	1,509,824

Tabla 14 – N° registros documentados y replicados en conjuntos de train, validación y test

Se observa una diferencia entre el número de registros en la muestra de test documentado en el archivo 01_resumen_estadistico.csv (1,338,493 registros) y el obtenido de la base de datos de test test_total.csv enviada por el cliente (1,509,824 registros). La diferencia de registros coincide con los registros del mes 202512 de test, por lo que se infiere que el análisis que se describe en este último archivo CSV no incluye este mes. Esta diferencia no se considera significativa y no afecta la consistencia ni la validez de los resultados aplicados, solo una inconsistencia entre lo documentado.

5.2.2.2. Variable respuesta

La variable respuesta (target) se ha construido a nivel cliente. No es posible replicar la construcción de la variable respuesta, debido a que esta se entrega previamente construida.

5.2.2.3. Creación de variables

No es posible replicar la creación de las variables, dado que la base de modelamiento fue proporcionada ya consolidada y no se contó con los insumos previos necesarios para validar su construcción desde origen.

5.2.2.4. Construcción del modelo

Para la réplica del modelo se utilizó la metodología descrita en la documentación del modelo, la cual se detalla en el apartado 4. Algoritmo XGBoost. Adicionalmente se utilizó el script 2.HPO.ipynb, el cual contiene el pipeline de optimización de hiperparámetros, entrenamiento y calibración del modelo. Dado que la optimización de hiperparámetros se realizó en AWS Sagemaker, no es posible replicar el entorno. Se replicó el modelo con los hiperparámetros documentados y las 36 variables documentadas, las cuales coinciden con las variables contenidas en las bases de datos proporcionadas por Interbank. Los hiperparámetros utilizados fueron los siguientes:

Hiperparámetro	Valor utilizado
objective	binary:logistic
eval_metric	auc
scale_pos_weight	494
max_depth	3
eta	0.07078304696565820
gamma	5.37418663066380
min_child_weight	7
subsample	0.816330164640324
colsample_bytree	0.844854997980621
num_round	457
early_stopping_rounds	200

Tabla 15 – Resumen hiperparámetros finales del modelo

La réplica del modelo será comparada con los indicadores de eficiencia y bondad de ajuste mencionados en el documento metodológico, ya que el objeto del modelo entrenado enviado por Interbank no coincide con la documentación y parece ser una versión anterior.

5.2.2.5. Indicadores de eficiencia y bondad de ajuste

Se comparan los indicadores de eficiencia y bondad de ajuste obtenidos en el proceso de réplica con los entregados por Interbank en el documento metodológico. Los resultados de dicha comparación para la muestra de entrenamiento no se presentan en el documento metodológico. Los resultados para la muestra de validación (métricas agregadas) y test (métricas mensuales) son los siguientes:

	Documentado	Réplica	Diferencia
Gini	91.572	91.44	0.132

Tabla 16 – Comparación Gini documentado y replicado en muestra de validación – Universo total

cod_mes	Documentado	Réplica	Diferencia gini
202508	92.72	93.43	0.71
202509	90.82	87.81	-3.01
202510	84.58	85.91	1.33

202511	88.95	88.76	-0.19
202512	87.17	90.39	3.22
202601	93.53	94.5	0.97
202602	92.23	91.83	-0.4
202603	86.41	89.72	3.31
202604	95.06	95.91	0.85

Tabla 17 – Comparación Gini mensual documentado y replicado en muestra de test – Universo total

Los resultados de la muestra test sobre alertas operativas son los siguientes:

cod_mes	Documentado	Réplica	Diferencia gini
202508	42.02	45.51	-3.49
202509	60.66	57.53	3.13
202510	64.7	65.92	-1.22
202511	44.12	40.62	3.5
202512	52.9	85.87	-32.97
202601	47.08	33.83	13.25
202602	55.44	62.45	-7.01
202603	32.76	36.85	-4.09
202604	46.4	48.46	-2.06

Tabla 18 – Comparación Gini mensual documentado y replicado en muestra de test – Solo alertas automáticas

Es importante observar las grandes diferencias de la métrica Gini documentada y la replicada para los meses de diciembre de 2025 y enero de 2026. Esto puede deberse al reducido tamaño muestral y a la variabilidad mensual de la tasa de positivos. En particular, diciembre de 2025 registra únicamente 2 casos positivos sobre 278 observaciones, situación que genera una elevada sensibilidad de las métricas en la réplica.

5.2.2.6. Matriz de importancia

Se compara la matriz de importancia obtenida en el proceso de réplica con la entregada por Interbank en el documento metodológico. En dicho documento, la importancia de cada variable fue evaluada mediante el valor SHAP promedio y su importancia relativa porcentual.

Feature	Documentado		Réplica		Diferencia	
	Mean_SHAP_Value	Importancia	Mean_SHAP_Value	Importancia	Mean_SHAP_Value	Importancia
cnt_trx_cargostot_3m	0,85922	15,587%	0,84954	15,2%	-0,00967	-0,4%

imp_trx_abonosefect_6m	0,60822	11,034%	0,58808	10,5%	-0,02014	-0,5%
pasivo_vs_ingresos	0,58852	10,676%	0,67529	12,1%	0,08677	1,4%
mto_pas_soles	0,44309	8,038%	0,51246	9,2%	0,06937	1,1%
imp_trx_cargosefe_6m	0,37405	6,786%	0,37427	6,7%	0,00021	-0,1%
cnt_alerta_hist	0,37253	6,758%	0,37628	6,7%	0,00375	0,0%
cnt_mesos_sinegresos_12m	0,31193	5,659%	0,29579	5,3%	-0,01614	-0,4%
mto_del_ext_12m	0,23305	4,228%	0,28281	5,1%	0,04976	0,8%
num_antiguedad	0,21291	3,862%	0,22718	4,1%	0,01427	0,2%
cod_ubigeo_cd	0,21115	3,830%	0,19770	3,5%	-0,01345	-0,3%
ingresos_vs_facturacion	0,18356	3,330%	0,14319	2,6%	-0,04036	-0,8%
ratio_abonos_1m_vs_6m	0,15515	2,815%	0,16632	3,0%	0,01117	0,2%
rat_mntorgsefetot_1m	0,13239	2,402%	0,11010	2,0%	-0,02229	-0,4%
cnt_trx_abonospromtot_3m	0,10781	1,956%	0,10552	1,9%	-0,00229	-0,1%
mto_fact_declarado_sunat	0,09937	1,803%	0,12236	2,2%	0,02299	0,4%
rat_trx_abonosefectot_9m	0,09010	1,634%	0,10465	1,9%	0,01455	0,2%
ratio_ingresos_exterior	0,08127	1,474%	0,05774	1,0%	-0,02353	-0,4%
ratio_cargos_1m_vs_6m	0,07488	1,358%	0,06169	1,1%	-0,01318	-0,3%
cod_sectorista_id	0,05305	0,962%	0,05407	1,0%	0,00102	0,0%
cnt_ros_hist	0,05092	0,924%	0,04941	0,9%	-0,00151	0,0%
rat_trx_abonosefectot_3m	0,04436	0,805%	0,01496	0,3%	-0,02939	-0,5%
ros_por_trx_3m	0,04147	0,752%	0,04676	0,8%	0,00530	0,1%
avg_trx_cargostot_3m	0,03424	0,621%	0,02934	0,5%	-0,00491	-0,1%
rat_trx_abonosefectot_1m	0,03165	0,574%	0,03957	0,7%	0,00792	0,1%
mto_al_ext_12m	0,01884	0,342%	0,01903	0,3%	0,00019	0,0%
max_mto_cpegrmen_12m	0,01853	0,336%	0,02370	0,4%	0,00518	0,1%
cnt_noticias	0,01728	0,314%	0,00794	0,1%	-0,00934	-0,2%
avg_cpmenegr_12m	0,01579	0,287%	0,02315	0,4%	0,00735	0,1%
flg_vrcn_abonos_5m_1m	0,01328	0,241%	0,00158	0,0%	-0,01170	-0,2%
ratio_egresos_exterior	0,01170	0,212%	0,00497	0,1%	-0,00673	-0,1%
share_cp_egresos	0,00831	0,151%	0,01089	0,2%	0,00257	0,0%
cnt_trx_sinenv_alex_12m	0,00723	0,131%	0,00862	0,2%	0,00138	0,0%
flg_alerta_12m	0,00296	0,054%	0,00782	0,1%	0,00485	0,1%
avg_cp_men_ing_12m	0,00211	0,038%	0,00369	0,1%	0,00158	0,0%
share_cp_ingresos	0,00145	0,026%	0,00000	0,0%	-0,00145	0,0%
flg_vrcn_efe_cargos_5m_1m	0,00000	0,000%	0,00000	0,0%	0,00000	0,0%

Tabla 19 – Comparación importancia de variables documentada y replicada

Como se observa en la tabla anterior, las variables *imp_trx_abono* y *sefect_6m* (monto total de abonos en efectivo en los u6m) y *pasivo_vs_ingresos* (pasivo total en soles vs ingresos totales en los u6m), que corresponden a la segunda y tercera variable en orden de importancia de acuerdo con lo documentado, en la réplica pasan al tercer y segundo lugar, respectivamente. Sin embargo, en general no se observan diferencias significativas de importancia de variables entre lo documentado y lo replicado.

5.2.3. Conclusiones y aspectos críticos

Se pudieron replicar los distintos resultados presentes en la documentación sin encontrar diferencias significativas en la muestra total, sin embargo, si se considera relevante las diferencias de la métrica Gini sobre las alertas operativas para los meses de diciembre de 2025 y enero de 2026. Los hallazgos de la réplica se han clasificado según su prioridad. Donde:

- Prioridad alta: se debe corregir la indicación, es un elemento inhabilitante.
- Prioridad media: Se debe tomar algún tipo de acción, pero no es un factor inhabilitante.
- Prioridad baja: Se sugiere corregir la indicación para mejorar la calidad de la documentación en este o futuros desarrollos.
- Limitación: Aspectos que no pudieron ser evaluados debido a las limitaciones propias del proceso.

Los hallazgos son los siguientes:

- Se observan diferencias relevantes entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601. Para mitigar esta alerta, se recomienda analizar el motivo que explique las diferencias de AUC y Gini en los meses de 202512 y 202601. (*Alerta alta*)
- Se recibe un objeto del modelo que no coincide con la documentación. Para mitigar esta alerta, se recomienda verificar que la documentación del modelo coincida el objeto del modelo oficial que será utilizado en producción. (*Alerta media*)
- El tamaño de la muestra de test no coincide con el documentado en el archivo de resumen estadístico. Para mitigar esta alerta, se recomienda estandarizar los análisis con el mismo periodo de evaluación. (*Alerta baja*)
- No se tienen los ID de clientes para la muestra de train, por lo que no se puede validar la unicidad en esta muestra. Para mitigar esta alerta, se recomienda incluir los id de los clientes en train para poder completar los análisis. (*Alerta baja*)

6. VALIDACIÓN METODOLÓGICA

En este apartado se revisan una serie de pruebas críticas respecto a la pertinencia y robustez del modelo, para lo cual se analizan los parámetros finales, proceso de modelización, bondad de ajuste, selección de variables, entre otros.

6.1. Revisión de la metodología

Se revisa la metodología no solo basándose en la documentación proporcionada, sino también analizando los criterios metodológicos que se han empleado para sustentar los modelos.

6.1.1. Descripción de las pruebas

Se realizan una serie de pruebas que tienen por objetivo analizar y contrastar los indicadores y criterios empleados en el desarrollo de los modelos, con el fin de comprobar si se adecúan a los mejores estándares. Para esto se analiza:

- Selección de la muestra: razonabilidad de los criterios para seleccionar la muestra de desarrollo del modelo, a partir de la definición del universo objetivo sobre el cual se utilizará el modelo.
- Definición variable respuesta: analizar si la variable respuesta es definida adecuadamente, considerando los estándares indicados por el supervisor.
- Metodología de desarrollo: análisis de la pertinencia de la metodología de desarrollo utilizada para el modelo, así como los filtros y estadísticos que se usaron para la selección de variables.
- Análisis hiperparámetros: se analizan los hiperparámetros seleccionados y método utilizado para su obtención.
- Metodología de validación: análisis de la metodología de validación, la cual debe ratificar que los resultados en términos de performance son robustos y estables.
- Medición performance: revisión de los indicadores utilizados para medir la performance o bondad de ajuste del modelo, la cual debe tener por objetivo contar con indicadores que permitan revisar que el modelo final tiene un nivel de precisión aceptable.

6.1.2. Resultados

Se revisan los resultados a nivel de cada uno de los elementos considerados en el desarrollo del modelo.

6.1.2.1. Selección de la muestra

Debido a la baja prevalencia de alertas con riesgo, se considera correcto usar todo el universo de casos positivos. Asimismo, se valora positivamente que la muestra esté compuesta de tres grupos: (1) alertas calificadas como con riesgo, (2) alertas calificadas como falsos positivos, (3) una muestra pequeña (0.5%) del universo de clientes sin alerta, pues mitiga parcialmente el sesgo de entrenar un modelo solo con los dos primeros grupos. Sin embargo, la proporción de clientes sin alerta elegida no está justificada y podría ser considerada como una decisión sin sustento metodológico. Cabe destacar que la conveniencia de incluir clientes sin alerta depende directamente del objetivo del modelo. Si el propósito es identificar qué clientes deberían ser investigados por el sistema de monitoreo, la incorporación de clientes sin alerta resulta conceptualmente adecuada. En cambio, si el objetivo es evaluar la capacidad discriminatoria del sistema de alertas automáticas entre alertas con y sin riesgo, la inclusión de clientes sin alerta podría no ser consistente con la población objetivo del problema. Se recomienda probar distintas combinaciones de proporciones de clientes sin alerta dentro de la muestra de desarrollo, para identificar cuál de ellas entrega mejores métricas y de este modo justificar la elección de la proporción óptima usando un criterio cuantitativo más defendible.

6.1.2.2. Definición de variable respuesta

La variable respuesta se define a partir de la clasificación realizada por los analistas, distinguiendo entre alertas catalogadas como “Con Riesgo” y “Falso Positivo”. En consecuencia, el modelo busca aproximar el criterio utilizado por los analistas PLAFT para evaluar las alertas generadas por los sistemas de monitoreo, actuando como un proxy del fenómeno de lavado de activos y financiamiento del terrorismo. Considerando que el desarrollo de modelos PLAFT se encuentra aún en una etapa relativamente incipiente, este enfoque se considera razonable. No obstante, debe tenerse presente que la clasificación de una misma alerta podría variar entre distintos analistas ante antecedentes similares, lo que introduce una fuente potencial de variabilidad en la variable objetivo. Este riesgo es inherente a los modelos basados en juicios expertos y constituye un desafío conocido en este ámbito (Berquist, 2024). Por otra parte, en la medida en que se disponga de información histórica suficiente y de una definición más directa del evento de interés, se recomienda evaluar el desarrollo de modelos orientados a explicar directamente el fenómeno PLAFT, reduciendo así la dependencia del criterio subjetivo de los analistas. Se recomienda indicar en la documentación como se mitigará el riesgo de que la misma alerta sea calificada positiva por un analista y negativa por otro. Adicionalmente, se recomienda avanzar hacia un enfoque donde se modele directamente el fenómeno PLAFT.

6.1.2.3. Metodología de desarrollo

Para el desarrollo del modelo se utilizó el algoritmo XGBoost, metodología cada vez más utilizada en la banca y aceptada por el regulador que tiende a tener mejor desempeño que modelos de regresión logística (o tradicionales) en riesgo de crédito¹.

El modelo desarrollado permite priorizar alertas generalizando el criterio usado por los analistas de investigación para identificar los casos con riesgo. Sin embargo, los siguientes hallazgos requieren atención inmediata:

1. No queda claro que las ventanas temporales del target y las variables explicativas sean disjuntas, si hay traslape temporal el modelo podría no ser aplicable porque "predice con el futuro".
2. No hay una separación explícita de clientes entre los conjuntos de train-test y validación. De hecho, se verifica que existen clientes presentes tanto en test como en validación. Debido a que la ventana temporal de entrenamiento más validación es relativamente corta (15 meses), existe un riesgo real de que las observaciones del mismo cliente en conjuntos distintos no sean independientes.
3. La calibración del modelo se hace sobre el mismo conjunto de validación, debería ser distinto.

Se recomienda revisar las fuentes de datos de origen del modelo, para garantizar que las variables explicativas contienen información de períodos anteriores al de predicción. En el proceso de construcción de las muestras de train, validación y test, se recomienda asegurar que un mismo cliente no esté presente en más de uno de estos conjuntos. En caso de que existan clientes compartidos entre las muestras, se recomienda documentar y justificar dicha situación, evaluando su potencial impacto sobre los resultados del modelo. Usar un conjunto que sea independiente al de validación para calibrar el modelo.

6.1.2.4. Metodología de selección de variables

El conjunto de variables seleccionadas para el modelo es adecuado, recogiendo información de distintos ámbitos, tales como: transaccionales, sociodemográficas, ratios financieros, comportamiento histórico AML, KYC, comercio exterior. Sin embargo, **no hay una descripción detallada del proceso que permite reducir el conjunto original de 305 variables a las 36 finales.**

¹ Guidolin, M., & Pedio, M. (2021). Sharpening the Accuracy of Credit Scoring Models with Machine Learning Algorithms.

Como referencia, en el script “*O.limpieza_datos.ipynb*” se describe un proceso de selección de variables a partir de un conjunto inicial de 187 variables, usando los siguientes criterios:

- Valores únicos (constantes).
- % de valores nulos superior a un umbral determinado (20%).
- Correlación de Pearson y Spearman superior a umbrales determinados (90% y 90%, respectivamente).

Estos criterios se consideran adecuados, pero los umbrales usados deberían justificarse. Además, se evidencia que no es la versión final del script usado para seleccionar las variables del modelo, pues se obtienen 28 variables explicativas, mientras que el modelo validado tiene 36 en total. Por lo tanto, es necesario documentar cuál es la relación de esta versión del script con la selección de variables finales del modelo.

6.1.2.5. Análisis hiperparámetros

El espacio de búsqueda usado para el desarrollo es adecuado. En particular, el hiperparámetro *scale_pos_weight* seleccionado con el valor de 494 indica que los casos positivos son ponderados para balancear la muestra al momento de entrenar el modelo, aunque esta ya viene balanceada previamente. Además, no se usan parámetros de regularización como lambda y alpha, que permiten reducir el overfitting y obtener predicciones más estables. Se recomienda complementar la documentación metodológica con una justificación del uso del hiperparámetro *scale_pos_weight*, considerando que previamente se realizó un proceso de balanceo de la muestra. Asimismo, se sugiere documentar los criterios que sustentan la decisión de no incorporar mecanismos de regularización durante el entrenamiento del modelo.

6.1.2.6. Medición performance

La metodología utilizada para medir el desempeño del modelo se considera adecuada, pero no suficiente. El uso de la precisión y el recall top K es necesario para medir cuál es el beneficio de la priorización de alertas. A diferencia de otros modelos predictivos con variable de respuesta binaria, las métricas habituales tales como el Gini o el KS no bastan por sí solas para medir el desempeño adecuadamente con la tipología del modelo validado. Asimismo, dentro del desarrollo del modelo se evidencia el uso del lift pero de forma experimental. Esta última métrica también se considera relevante y debería ser incluida en la presentación de resultados oficiales del modelo.

6.1.2.7. Auditoría de datos

Todas las observaciones o dudas fueron contestadas de manera oportuna por los dueños del modelo. No se encuentran observaciones relevantes en cuanto a las distribuciones de las variables del modelo.

6.1.3. Conclusiones y aspectos críticos

En términos generales, si bien la metodología empleada se considera razonable, a continuación se presentan indicaciones asociadas a los hallazgos metodológicos más relevantes identificados durante la validación del modelo. Donde:

- Prioridad Alta: se debe corregir la indicación con urgencia.
- Prioridad Media: se debe corregir la indicación, no es un factor inhabilitante.
- Prioridad Baja: se sugiere corregir la indicación para mejorar la calidad de la documentación.

Las observaciones son las siguientes:

- Respecto al proceso de desarrollo del modelo, (1) no queda claro que las ventanas temporales del target y las variables explicativas sean disjuntas, (2) no hay una separación explícita de clientes entre los conjuntos de train-test y validación, y (3) la calibración del modelo se hace sobre el mismo conjunto de validación. Para mitigar esta alerta, se recomienda (1) revisar las fuentes de datos de origen del modelo, para garantizar que las variables explicativas contienen información de períodos anteriores al de predicción, (2) en la construcción de las muestras de train, test y validación, garantizar que un cliente pueda aparecer en exactamente una de las tres, para garantizar la independencia del conjunto de validación, y (3) usar un conjunto que sea independiente al de validación para calibrar el modelo. *(Alerta media)*
- La proporción de clientes sin alerta elegida no está justificada y podría ser considerada como una decisión sin sustento metodológico. Para mitigar esta alerta, se recomienda probar distintas combinaciones de proporciones de clientes sin alerta dentro de la muestra de desarrollo, para identificar cuál de ellas entrega mejores métricas y de este modo justificar la elección de la proporción óptima usando un criterio cuantitativo más defendible. *(Alerta baja)*
- No hay una descripción detallada del proceso que permite reducir el conjunto original de 305 variables a las 36 finales, ni tampoco una justificación del uso de los umbrales en los criterios de % de valores nulos y de correlaciones. Para mitigar esta alerta, se

recomienda incluir en documento metodológico el proceso de selección descrito en el script “0.limpieza_datos.ipynb”, pero usando la versión final que permita llegar al universo de 36 variables del modelo validado a partir de las 305 variables iniciales de acuerdo con el documento, y justificar los umbrales usados en los criterios de % de valores nulos y de correlaciones (20% y 90%, respectivamente), así como también aclarar si los criterios y umbrales mencionados son los mismos que se usan para la selección final de variables. (*Alerta baja*)

7. ANÁLISIS DE LAS VARIABLES

7.1. Descripción de las pruebas

En este apartado se hace un breve análisis de las variables antes y después del desarrollo de los modelos:

- **Auditoría de datos:** Se extraen estadísticos descriptivos de las variables con el objetivo de lograr entender su distribución y detectar anomalías.
- **Importancia de las variables:** Se analiza la coherencia y magnitud de la importancia de las variables dentro del modelo. Se espera que las variables no tengan un peso mayor al 20% (sobre explicativa) ni menor al 0.1% (variable poco importante). Además, que el orden de importancia tenga sentido de negocio.

7.2. Resultados

7.2.1. Auditoría

El detalle de la auditoría de datos se encuentra en el documento “*Ubimia - Interbank - Réplica - Auditoría variables modelo PLAFT.xlsx*”, proporcionado por Ubimia. Dependiendo si las variables son numéricas o categóricas los análisis son los siguientes:

- **Variables numéricas:** Se han identificado aquellas variables numéricas relevantes para el proceso. A estas variables identificadas, se les ha realizado pruebas de completitud y de integridad/coherencia de sus valores (por ejemplo, revisando que no existan valores negativos o se encuentren dentro de umbrales lógicos), mediante número de missings, análisis estadísticos de medias y percentiles, adicionalmente se revisa la estabilidad de las variables con el Índice de estabilidad poblacional.
- **Variables alfanuméricas:** A estas variables identificadas, se les ha realizado pruebas de completitud y de integridad/coherencia de sus valores revisando individualmente los posibles valores que están tomando dichas variables.

Adicionalmente, se incluye resumen de los resultados de la auditoría de variables.

7.2.2. Importancia de las variables

Se verifica durante la validación que ninguna variable sobrepasa el umbral superior del 20% de importancia, definido en el Manual de Indicadores y Umbrales de Interbank. Sin embargo, hay cuatro variables por debajo del umbral inferior del 0.1% definido en el mismo manual (flg_alerta_12m, avg_cp_men_ing_12m, share_cp_ingresos, flg_vrcn_efc_cargos_5m_1m),

las cuales se recomienda eliminar a menos de que exista un criterio de negocio que lo justifique.

7.2.3. Missing

Respecto al tratamiento de missings realizado a las variables del modelo.

- Las variables categóricas fueron completadas con el valor “SIN_INFO”, lo cual se considera adecuado.
- Las variables numéricas se rellenan con ceros, **lo cual es inadecuado para variables de variaciones, ratios y antigüedad del cliente**. En estos casos, las variables deben ser imputadas de acuerdo con el significado de la variable y del valor missing. Debido a que los conjuntos de datos vienen con las imputaciones ya aplicadas, no es posible cuantificar cuál es el impacto de esto.

En virtud de lo anterior, se recomienda cuantificar en la etapa de preprocesamiento el % de missings, justo después de ejecutar la query de extracción de datos desde AWS Athena. En particular, en el caso de las variables numéricas, deben definirse estrategias de imputación adecuadas, teniendo en cuenta el significado de cada variable y valor missing asociado a esta.

7.3. Conclusiones y aspectos críticos

A continuación, se presentan indicaciones relacionadas a análisis de variables identificadas durante la validación del modelo. Donde:

- Prioridad Alta: se debe corregir la indicación con urgencia.
- Prioridad Media: se debe corregir la indicación, no es un factor inhabilitante.
- Prioridad Baja: se sugiere corregir la indicación para mejorar la calidad de la documentación.

Las observaciones son las siguientes:

- Las variables numéricas se rellenan con ceros, lo cual es inadecuado para variables de variaciones, ratios y antigüedad del cliente. Para mitigar esta alerta, se recomienda usar estrategias de imputación adecuadas, dependiendo del significado de la variable y del valor missing. (*Alerta media*)

8. RENDIMIENTO Y VALIDACIÓN

Se analiza la performance o bondad de ajuste del modelo, además se comparan los resultados con la validación del modelo.

8.1. Descripción de las pruebas

Para analizar el rendimiento del modelo se realizan una serie de pruebas, las cuales además comparan los resultados entre la muestra de desarrollo y de validación para ver estabilidad de los resultados:

- GINI
- AUC

8.2. Resultados

8.2.1. Métricas de performance

La documentación metodológica establece que el proceso de optimización del modelo se realizó utilizando como métrica objetivo el Área Bajo la Curva ROC (AUC), obteniendo un valor de 0.9904 para la muestra de entrenamiento y 0.9585 para la muestra de validación. La diferencia entre ambos resultados equivale aproximadamente a 6.4 puntos de Gini, lo que sugiere la existencia de un ligero sobreajuste, aunque este se considera razonable dada la baja proporción de casos positivos característica del problema. Asimismo, durante la revisión de los scripts de desarrollo se verificó que el proceso de optimización de hiperparámetros mediante Amazon SageMaker HPO utiliza consistentemente el AUC como métrica de optimización, observándose valores cercanos a 0.9995 sobre la muestra de validación para el score previo y posterior a la calibración de probabilidades.

No obstante, desde el punto de vista de la validación metodológica, se considera que el AUC, si bien es una métrica adecuada para optimizar y comparar modelos de clasificación, no resulta suficiente para evaluar el desempeño de un modelo cuyo objetivo operacional es priorizar alertas de mayor riesgo. En este tipo de aplicaciones adquieren mayor relevancia métricas como la precisión (Precision) y la sensibilidad (Recall) en los segmentos de mayor score (Top K o quintiles superiores), ya que permiten cuantificar la capacidad del modelo para concentrar los casos positivos dentro del universo de alertas que efectivamente serán revisadas por los analistas. Si bien estas métricas fueron identificadas en los scripts de desarrollo para la evaluación sobre la muestra de prueba, no se reportan para las etapas de entrenamiento y validación, ni tampoco sobre el subconjunto de alertas automáticas que representa el

escenario operativo del modelo. La incorporación de estos indicadores en la documentación permitiría contar con una evaluación más alineada con el objetivo de negocio y facilitaría el seguimiento de la capacidad predictiva del modelo durante su ciclo de vida.

La evaluación del modelo sobre la muestra de test evidencia un desempeño adecuado para el objetivo de priorización de alertas (información observada en los scripts). De acuerdo con los resultados obtenidos durante el desarrollo, las métricas de precisión (Precision) y sensibilidad (Recall) para distintos valores de Top K (100, 200, 500, 1.000 y 2.000) presentan niveles consistentes con un problema de clasificación altamente desbalanceado, observándose que la precisión en el Top 100 se sitúa entre aproximadamente 7% y 18%, lo que indica que el modelo concentra una proporción relevante de los casos positivos en los registros de mayor score.

En términos generales, los resultados obtenidos en validación respaldan la capacidad discriminatoria del modelo y son consistentes con su propósito de priorizar la revisión de alertas con mayor probabilidad de riesgo. No obstante, se considera que el seguimiento periódico de estas métricas debería realizarse sobre períodos que acumulen un volumen suficiente de observaciones, dado que la baja frecuencia del evento objetivo genera una elevada variabilidad cuando los indicadores se calculan de forma mensual. En consecuencia, una evaluación agregada sobre horizontes temporales más amplios permitiría obtener métricas más estables y representativas del desempeño real del modelo en producción.

8.2.2. Conclusiones y aspectos críticos

Los hallazgos son los siguientes:

- El AUC se considera una métrica inadecuada para definir si el modelo tiene buenos niveles de predicción en su entrenamiento. Para mitigar esta alerta, se recomienda incluir los resultados de precisión y recall top K en las muestras de train y validación, al momento de entrenar el modelo. Asimismo, las métricas deberían ser reportadas en el universo de alertas automáticas. (*Alerta baja*)

9. CONCLUSIONES Y SUGERENCIAS

A continuación, se destacan algunos de los puntos más relevantes de la validación:

Revisión documental

La documentación metodológica permite comprender los aspectos más relevantes del proceso de desarrollo del modelo (obtención base inicial, filtros aplicados, definición buenomalo, análisis temporal inicial, modelización, algoritmo utilizado, métricas y resultados). Sin embargo, no se alinea con los estándares de documentación de Interbank.

El objetivo del modelo, la definición de la población, la variable de respuesta y el uso previsto son coherentes con el desarrollo analítico. Sin embargo, la población objetivo presenta ambigüedad en su definición y falta incluir el tamaño de las muestras, junto con sus tasas de positivos. Asimismo, en el caso de la variable de respuesta es relevante especificar el significado del horizonte de evaluación de 30 días.

Los procesos de construcción, transformación, selección de variables y calibración del modelo no se encuentran suficientemente documentados, limitando trazabilidad y reproducibilidad del modelo. A su vez, la documentación de desempeño y validación debe fortalecerse, incorporando todas las métricas utilizadas y los resultados por muestra.

Réplica y Data Quality

En general, se observa que los tamaños de muestra documentados coinciden con los replicados a partir de los datos recibidos. Sin embargo, debe detallarse con mayor precisión los conjuntos de datos utilizados en cada etapa del proceso de modelamiento. Respecto a la unicidad de los datos, se verifica que las bases no contienen duplicados.

La construcción de la muestra, la variable de respuesta y de las variables explicativas no pudo ser replicada, debido a que no se recibieron los insumos, así como tampoco la optimización de hiperparámetros, debido a que se hizo en AWS Sagemaker y para la réplica no se dispone de esta herramienta. Si bien hay una diferencia en los entornos de trabajo, sí se logró la réplica del modelo sin diferencias significativas, asumiendo los mismos hiperparámetros que los obtenidos por Interbank.

Un hallazgo crítico del proceso de validación es que el objeto del modelo entrenado no coincide con la documentación, lo que debe ser subsanado en futuras versiones del documento metodológico.

Otro hallazgo crítico es que, al aplicar el filtro de alertas automáticas y riesgo de cliente, que es el universo productivo, se observan diferencias significativas entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601, lo cual debe ser analizado en detalle.

Revisión metodológica

El modelo validado incluye información desde múltiples fuentes, que se consideran relevantes para el modelamiento y aportan un grado de riqueza adecuado para construir variables explicativas. Sin embargo, no hay trazabilidad completa del proceso de selección de variables creadas a partir de estas fuentes.

Respecto a la variable de respuesta, se considera relevante abordar el riesgo de que la misma alerta sea calificada como positiva por un analista y negativa por otro analista. Respecto a la selección de la muestra, se valora que se aproveche el universo completo de casos con alertas marcados como positivos. Asimismo, el balanceo de 0.5% de alertas positivas y 99.5% de alertas negativas se considera adecuado. Respecto a la conveniencia de incluir clientes sin alerta, esto depende directamente del objetivo del modelo. De todas maneras, se observa que la proporción de clientes sin alerta elegida (0.5%) no está justificada y podría ser considerada como una decisión sin sustento metodológico.

Respecto al proceso de desarrollo del modelo, se observan hallazgos críticos que deben ser analizados en detalle: (1) posible traslape temporal entre las variables explicativas y el target, (2) existencia de los mismos clientes en más de una muestra y (3) uso del conjunto de validación para calibrar el modelo.

Otro hallazgo crítico relacionado a metodología es que se observan variables numéricas que se rellenan con ceros de forma inadecuada desde el punto de vista técnico, tales como ratios, y el impacto de esto debe ser cuantificado.

Performance

El uso de Gini es inadecuado en el contexto del modelo validado, con poca materialidad de casos positivos. En su defecto, se recomienda el uso de precisión y recall top K, así como también el lift. En la misma línea, abrir el análisis por mes es desaconsejable, pues dificulta la evaluación del rendimiento del modelo. Teniendo en cuenta lo anterior, las métricas mensuales de Gini obtenidas en la muestra de test son consistentes con la métrica global observada en

validación, difiriendo mensualmente en un máximo de 10% (esperable por la baja cantidad de casos positivos).

Un hallazgo importante asociado al performance es la disminución en el desempeño del modelo al filtrar las muestras por alertas operativas. Mientras que en la muestra de test completa se observan valores de Gini cercanos al 90%, en el subconjunto de alertas operativas el desempeño se reduce hasta niveles promedio cercanos al 50%. Esto resulta particularmente relevante, debido a que dicho subconjunto corresponde al universo objetivo sobre el cual se espera aplicar el modelo en producción.

Conclusión general

En base al proceso de réplica y validación metodológica desarrollado presentado en este informe, se concluye que **el Modelo PLAFT Persona Jurídica Minorista presenta hallazgos metodológicos y limitaciones de replicabilidad que requieren análisis y revisión adicional**. Entre los principales hallazgos se identifican diferencias relevantes entre el desempeño documentado y el replicado sobre el universo operativo de alertas, junto con una reducción significativa de la capacidad discriminatoria del modelo al evaluarlo sobre la población objetivo de producción. En consecuencia, se recomienda profundizar el análisis de los hallazgos identificados y fortalecer la documentación metodológica antes de emitir una conclusión definitiva respecto de la idoneidad del modelo para su uso en producción.

Adicionalmente, se identifican las siguientes recomendaciones con alerta:

Documentación

1. El documento metodológico no se alinea con los estándares de documentación de Interbank, por ejemplo, no tiene el logo, tipografía, colores corporativos, índice, control de versiones, anexos, bibliografía. Para mitigar esta alerta, se recomienda alinear la documentación a los estándares de Interbank. (*Alerta media*)
2. La población objetivo presenta ambigüedad en su definición. Para mitigar esta alerta, se recomienda estandarizar la definición de la población objetivo en todo el documento para mayor coherencia. (*Alerta baja*)
3. Se define un horizonte de evaluación de 30 días, sin embargo, no se describe qué significa dicho horizonte. Para mitigar esta alerta, se recomienda describir el significado del horizonte de evaluación para mayor claridad y entendimiento del problema. (*Alerta baja*)

4. No se cuenta con un diccionario de variables formal. Para mitigar esta alerta, se recomienda elaborar un diccionario formal de variables. (*Alerta baja*)
5. El documento no detalla el tamaño de las muestras resultantes en cada etapa del proceso. Adicionalmente, se identifica una inconsistencia en la definición temporal de las muestras de desarrollo (train) y prueba (test). Para mitigar esta alerta, se recomienda documentar el número de registros de cada muestra junto con su tasa de positivos y corregir el periodo de las muestras de desarrollo y test. (*Alerta baja*)
6. La población corresponde a un subsegmento específico (BPE, o Banca Pequeña Empresa). Esto no se encuentra descrito en el documento metodológico. Para mitigar esta alerta, se recomienda mencionar en el documento metodológico que la población corresponde al subsegmento específico de BPE. (*Alerta baja*)
7. A nivel documental, no se dispone del detalle del proceso de creación y procesamiento de las variables. Para mitigar esta alerta, se recomienda documentar el proceso de creación y procesamiento de las variables. (*Alerta baja*)
8. No se documenta el detalle de la exclusión de variables, los criterios aplicados y las variables descartadas en cada etapa del proceso. Para mitigar esta alerta, se recomienda detallar el proceso de selección de variables. (*Alerta baja*)
9. Si bien se describe las ventajas de la calibración del modelo, no se detallan las técnicas utilizadas ni la muestra. Además, respecto al balanceo de clases, se omiten aspectos relevantes. Para mitigar esta alerta, se recomienda detallar las técnicas utilizadas del proceso de calibración y la muestra utilizada y los tamaños de las clases antes y después del balanceo. (*Alerta baja*)
10. No aparecen en el documento las métricas relevantes para validar este tipo de modelos, tales como precisión y recall top K, que sí se incluyen en los scripts de desarrollo. Para mitigar esta alerta, se recomienda incluir en el documento metodológico métricas de validación que se usan en el desarrollo, tales como precisión y recall top K. (*Alerta baja*)

Réplica y Data Quality

1. Se observan diferencias relevantes entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601. Para mitigar esta alerta, se recomienda analizar el motivo que explique las diferencias de AUC y Gini en los meses de 202512 y 202601. (*Alerta alta*)

2. Se recibe un objeto del modelo que no coincide con la documentación. Para mitigar esta alerta, se recomienda verificar que la documentación del modelo coincida el objeto del modelo oficial que será utilizado en producción. (*Alerta media*)
3. El tamaño de la muestra de test no coincide con el documentado en el archivo de resumen estadístico. Para mitigar esta alerta, se recomienda estandarizar los análisis con el mismo periodo de evaluación. (*Alerta baja*)
4. No se tienen los ID de clientes para la muestra de train, por lo que no se puede validar la unicidad en esta muestra. Para mitigar esta alerta, se recomienda incluir los id de los clientes en train para poder completar los análisis. (*Alerta baja*)

Metodología

1. Respecto al proceso de desarrollo del modelo, (1) no queda claro que las ventanas temporales del target y las variables explicativas sean disjuntas, (2) no hay una separación explícita de clientes entre los conjuntos de train-test y validación, y (3) la calibración del modelo se hace sobre el mismo conjunto de validación. Para mitigar esta alerta, se recomienda (1) revisar las fuentes de datos de origen del modelo, para garantizar que las variables explicativas contienen información de períodos anteriores al de predicción, (2) en la construcción de las muestras de train, test y validación, garantizar que un cliente pueda aparecer en exactamente una de las tres, para garantizar la independencia del conjunto de validación, y (3) usar un conjunto que sea independiente al de validación para calibrar el modelo. (*Alerta media*)
2. Las variables numéricas se rellenan con ceros, lo cual es inadecuado para variables de variaciones, ratios y antigüedad del cliente. Para mitigar esta alerta, se recomienda usar estrategias de imputación adecuadas, dependiendo del significado de la variable y del valor missing. (*Alerta media*)
3. La proporción de clientes sin alerta elegida no está justificada y podría ser considerada como una decisión sin sustento metodológico. Para mitigar esta alerta, se recomienda probar distintas combinaciones de proporciones de clientes sin alerta dentro de la muestra de desarrollo, para identificar cuál de ellas entrega mejores métricas y de este modo justificar la elección de la proporción óptima usando un criterio cuantitativo más defendible. (*Alerta baja*)
4. No hay una descripción detallada del proceso que permite reducir el conjunto original de 305 variables a las 36 finales, ni tampoco una justificación del uso de los umbrales en los criterios de % de valores nulos y de correlaciones. Para mitigar esta

alerta, se recomienda incluir en documento metodológico el proceso de selección descrito en el script "*0.limpieza_datos.ipynb*", pero usando la versión final que permita llegar al universo de 36 variables del modelo validado a partir de las 305 variables iniciales de acuerdo con el documento, y justificar los umbrales usados en los criterios de % de valores nulos y de correlaciones (20% y 90%, respectivamente), así como también aclarar si los criterios y umbrales mencionados son los mismos que se usan para la selección final de variables. (*Alerta baja*)

Performance

1. El AUC se considera una métrica inadecuada para definir si el modelo tiene buenos niveles de predicción en su entrenamiento. Para mitigar esta alerta, se recomienda incluir los resultados de precisión y recall top K en las muestras de train y validación, al momento de entrenar el modelo. Asimismo, las métricas deberían ser reportadas en el universo de alertas automáticas. (*Alerta baja*)

10.ANEXO


A continuación, se detallará el procedimiento de las pruebas analizadas anteriormente.

10.1. Coeficiente de Gini

El coeficiente de Gini nos informa de la potencia de segmentación entre buenos y malos de un modelo (a través del scoring) o una variable. Este coeficiente mide el grado de concentración de un atributo en una población, en este caso estamos midiendo el grado de concentración de las operaciones malas en la cartera según valor de la variable que se está utilizando para discretizar entre buenos y malos. Si este coeficiente tomase valor cero, cuando la curva coincidiese con la bisectriz, estaríamos delante un caso de no concentración, es decir las operaciones malas, o buenas, se distribuyen de forma uniforme en los distintos valores de la variable que se utiliza para discretizar, por lo cual se dice que la variable no es capaz de distinguir entre malos y buenos.

Gráficamente, el coeficiente de GINI es el cociente entre 2 áreas:


$$GINI = \frac{A}{A + B}$$



10.2. Coeficiente de ROC

La curva ROC (*Receiver Operating Characteristic*), representa la relación existente entre la Sensibilidad (eje vertical) y 1 – Especificidad (eje horizontal) para un conjunto de puntos de corte, para una variable categórica binaria ("buenos", "malos")

La Sensibilidad representa el porcentaje de aciertos en los clasificados como "buenos" por el modelo (o sea, la tasa de verdaderos positivos), y 1 – Especificidad representa el porcentaje de fallos en los clasificados como "buenos" por el modelo (o sea, la tasa de falsos positivos).



El área bajo la curva ROC (AUC - *Area Under the Curve*), que es el área que se encuentra por debajo de la curva ROC (en rojo en el gráfico), permite comparar diferentes curvas ROC. Se calcula del siguiente modo:

$$AUC = \int_0^1 Sens \times (1 - Esp) \times d(1 - Esp),$$

Donde *Sens* es la sensibilidad y *Esp* la especificidad.

Los conceptos de curva ROC y AUC se pueden extender a variables de tipo continuo, siempre que se tome una definición de "bueno" y "malo". Por ejemplo:

- El valor de una variable se categoriza como "Bueno" si dicho valor es menor que el promedio muestral de la variable, y como "Malo" en caso contrario.

A partir de ahí, se ordena cada elemento de la muestra según el valor continuo de la variable y se clasifica en función del criterio de "bueno" y "malo".

Nota: El área bajo la curva ROC se puede obtener en función del Gini, siendo: $(Gini+1)/2$.