

Validación Modelo PLAFT Persona Jurídica Minorista



Agenda

1

Alcances de la validación

2

Resumen del modelo

3

Resultados

4

Conclusiones



Alcances de la validación

Etapas a evaluar

Revisión documental

- Revisión de la completitud de las bases de datos y documentación enviada por el cliente.
- Revisión de la coherencia de la información recibida, con la documentada.

Réplica y Data Quality

- Replica el proceso de construcción del modelo verificando que los resultados obtenidos sean iguales a los documentados.
- Revisión de la calidad de las bases de datos y variables de origen con la que es construido el modelo.

Revisión metodológica

- Revisión crítica, cualitativa y cuantitativa de la metodología utilizada para sustentar los modelos con el objetivo de verificar si se adecúan a los mejores estándares.



Resumen del modelo

Desarrollo de nuevo modelo PLAFT

El modelo Plaft Persona Jurídica Minorista ha sido construido con el objetivo de estimar la probabilidad de que una alerta generada por el sistema de monitoreo sea clasificada como “Con Riesgo” por los analistas PLAFT para clientes del segmento de persona jurídica minorista.

Definiciones



Población: Clientes de Interbank del segmento Personas Jurídicas Minorista con alertas levantadas por el Sistema de Monitoreo.

Variable respuesta: Un cliente con alerta es clasificado como malo cuando un analista de investigación lo califica como “Con Riesgo”. En caso contrario, el cliente es calificado como “Falso Positivo”.

Variables explicativas: Se seleccionan 36 variables finales, a partir de un universo inicial de 305 variables.

Volumetría



Las muestras de desarrollo y prueba abarcan información entre ene-2025 y jul-2025.

La muestra de validación oot se constituyó con información entre ago-2025 y abr-2026.

Resultados

En el desarrollo del modelo PLAFT, se utilizó el algoritmo de XGBoost, siguiendo metodologías de Machine Learning.

Muestra



El muestreo se realizó del siguiente modo:

1. Se selecciona el universo de clientes del subsegmento BPE de la base de alertas de los meses entre ene-2025 y mar-2026.
2. Se separa el universo anterior en clientes antiguos (correspondientes a los meses entre ene-2025 y jul-2025) y recientes (ago-2025 a mar-2026). Estos últimos son reservados como conjunto de test (OOT).
3. Del universo de clientes antiguos con alertas, se seleccionan todos los casos positivos (=marcados “Con Riesgo” por analistas de investigación) disponibles y de los casos negativos se elige una muestra aleatoria, de tal modo que las proporciones sean 0.5% y 99.5%, respectivamente.
4. Al conjunto obtenido en el paso anterior, se le suma un 0.5% del universo de clientes antiguos sin alertas.

Rendimiento



El performance del modelo en las muestras de validación y test es el siguiente:

Conjunto de validación

Universo total

Métrica	Documentado
Gini	91,572

Conjunto de test

Universo total

Mes	Gini
202508	93.43
202509	87.81
202510	85.91
202511	88.76
202512	90.39
202601	94.50
202602	91.83
202603	89.72
202604	95.91



Aplicando el filtro de alertas automáticas, en línea con el uso en producción.

Conjunto de test

Solo alertas automáticas

Mes	Gini
202508	42.02
202509	60.66
202510	64.70
202511	44.12
202512	52.90
202601	47.08
202602	55.44
202603	32.76
202604	46.40



Resultados

Significado de alertas

Valoración	Alerta	Explicación
	Sin Alerta	El ámbito fue validado y no se encontraron incidencias.
	Baja	Se sugiere considerar la indicación con el fin de mejorar la calidad de la documentación y/o reforzar buenas prácticas metodológicas en este o futuros desarrollos
	Media	Se debe tomar algún tipo de acción, pero no es un factor inhabilitante
	Alta	Se debe corregir la indicación, es un elemento inhabilitante
	Limitación	Aspectos que no pudieron ser evaluados debido a las limitaciones propias del proceso
	Aspecto de mejora	Sugerencias de mejora que aportan al fortalecimiento técnico, metodológico o documental del modelo. No constituyen una alerta de validación.

RESULTADOS

 Revisión documental

 Réplica y Data Quality

 Metodología

 Performance

Revisión documental

Ámbito

Prueba

Resultado

Recomendación

Valoración

Revisión
documental

Diccionario de datos

No se cuenta con un diccionario de variables formal.

Sin embargo, se dispone de dos archivos que proporcionan información de las variables:

- Importancia_variables.csv: El documento presenta la información de las 36 variables predictoras del modelo. Contiene 4 columnas: nombre de la variable, importancia, valor absoluto SHAP y descripción. **Hay 4 variables sin descripción.**
- T_AGG_ALERTAS_PLAFT_Matriz_Equivalencia.xlsx: Este archivo contiene una tabla agregada de alertas plaft de aws. Contiene la información de 286 variables, se infiere que es el conjunto de variables previo al procesamiento y selección de variables finales.

Si bien se dispone de dos documentos que describen las variables del modelo, se recomienda elaborar un diccionario formal de variables que incluya, como mínimo, la siguiente información:

- Nombre de la variable
- Descripción
- Tipo de dato
- Fuente de origen
- Dominio o valores permitidos



Revisión documental

Ámbito	Prueba	Resultado	Recomendación	Valoración
Revisión documental	Ámbito objetivo	Se describe adecuadamente el objetivo del modelo, orientado a la estimación de la probabilidad de que una alerta sea clasificada como "con riesgo". La población objetivo presenta ambigüedad en su definición , en la primera definición no se menciona el porcentaje de muestra "sin alerta" que se incluye como falso positivo (target cero).	Se recomienda estandarizar la definición de la población objetivo en todo el documento para mayor coherencia.	
	Variable respuesta	El target del modelo corresponde a una clasificación binaria que representa si una alerta generada por el sistema de monitoreo es clasificada o no como "alerta con riesgo" por los analistas de investigación. Se evidencia una inconsistencia en la definición de la clase negativa, ya que posteriormente en el documento se menciona que se incorporan registros sin alertas como "falsos positivos". Se define un horizonte de evaluación de 30 días, sin embargo, no se describe qué significa dicho horizonte .	Se recomienda estandarizar la definición de la clase negativa en la variable respuesta en todo el documento para mayor coherencia. Además, se recomienda describir el significado del horizonte de evaluación para mayor claridad y entendimiento del problema.	

Revisión documental

Ámbito	Prueba	Resultado	Recomendación	Valoración
Revisión documental	Definición creación de la muestra	Se evidencia la definición del proceso de obtención de la muestra, incluyendo las fuentes de información integradas para la construcción de la base inicial y los filtros aplicados posteriormente. Sin embargo, el documento no detalla el tamaño de las muestras resultantes en cada etapa del proceso. Adicionalmente, se identifica una inconsistencia en la definición temporal de las muestras de desarrollo (train) y prueba (test). Inicialmente se indica que la muestra de prueba comienza en octubre; no obstante, los análisis posteriores se realizan utilizando información desde agosto. Una situación similar se observa en la muestra de desarrollo.	Se recomienda documentar el número de registros de cada muestra junto con su tasa de positivos. Se recomienda corregir el periodo de las muestras de desarrollo y test.	

Revisión documental

Ámbito	Prueba	Resultado	Recomendación	Valoración
Revisión documental	Análisis estadísticos variables candidatas	Se evidencia la realización de análisis estadísticos de las variables en dos documentos (muestra de desarrollo y test), incluyendo estadísticos descriptivos (media, mediana, desviación estándar, percentiles, outliers, valores mínimos y máximos). El análisis descriptivo de las variables categóricas ('cod_ubigeo_cd', 'cod_sectorista_id', 'flg_alerta_12m', 'flg_vrcn_abonos_5m_1m' y 'flg_vrcn_efe_cargos_5m_1m') se realizó utilizando estadísticas de tendencia central y dispersión propias de variables numéricas. Dado que estas métricas poseen una interpretación limitada o nula para variables categóricas, se recomienda complementar el análisis mediante tablas de frecuencia, las cuales resultan más adecuadas para caracterizar este tipo de variables.	Se recomienda complementar el análisis de las variables categóricas mediante tablas de frecuencia.	
	Análisis de segmentación	No aplica segmentación, debido a que, de acuerdo con los códigos de desarrollo, la población corresponde a un subsegmento específico (BPE, o Banca Pequeña Empresa). Esto no se encuentra descrito en el documento metodológico.	Mencionar en el documento metodológico que la población corresponde a un subsegmento específico.	

Revisión documental

Ámbito	Prueba	Resultado	Recomendación	Valoración
Revisión documental	Metodologías complementarias para variables	A nivel documental, no se dispone del detalle del proceso de creación y procesamiento de las variables.	Se recomienda documentar el proceso de creación y procesamiento de las variables.	
	Selección de variables	Se realizó un proceso de selección de variables que redujo 305 variables originales a 36 variables predictoras finales. Se eliminaron variables con bajo aporte informativo y altamente correlacionadas. No se documenta el detalle de la exclusión de variables, los criterios aplicados y las variables descartadas en cada etapa del proceso.	Se recomienda detallar el proceso de selección de variables.	

Revisión documental

Ámbito	Prueba	Resultado	Recomendación	Valoración
Revisión documental	Metodología de construcción del modelo	La documentación describe la metodología de construcción del modelo PLAFT basado en XGBoost con su posterior calibración de probabilidades. Se detalla la elección de hiperparámetros, el objetivo de cada uno y la ejecución del proceso HPO. Si bien se describe las ventajas de la calibración del modelo, no se detallan las técnicas utilizadas ni la muestra. Además, respecto al balanceo de clases, se omiten aspectos relevantes (p. ej. undersampling/oversampling).	Detallar las técnicas utilizadas del proceso de calibración y la muestra utilizada. Detallar tamaños de las clases antes y después del balanceo.	
	Metodología de validación	Se incluyen en el documento metodológico valores de Gini y AUC en período OOT. Sin embargo, no aparecen en el documento las métricas relevantes para validar este tipo de modelos, tales como precisión y recall top K, que sí se incluyen en los scripts de desarrollo.	Incluir en el documento metodológico métricas de validación que se calculan en el script de desarrollo, tales como precisión y recall top K.	

Revisión documental

Ámbito	Prueba	Resultado	Recomendación	Valoración
Revisión documental	Suficiencia documentación (completitud y coherencia)	La documentación presenta, de forma muy general, los aspectos más relevantes del proceso de desarrollo del modelo (obtención base inicial, filtros aplicados, definición bueno-malo, análisis temporal inicial, modelización, algoritmo utilizado, métricas y resultados). Sin embargo, se identifican diversos elementos que requieren ser mejorados y/o incorporados. Induir: - Estandarización de la definición de población objetivo y target en todo el documento. - Significado del horizonte de evaluación. - Diccionario formal de variables. - Número de registros de cada muestra junto con su tasa de positivos. - Periodo de muestras de train y test corregido. - Mención del subsegmento considerado (BPE). - Creación y procesamiento de las variables. - Proceso de selección de variables. - Técnicas utilizadas del proceso de calibración y la muestra utilizada. - Tamaños de clases antes y después del balanceo. - Métricas de validación usadas en el desarrollo. Mejorar: - Análisis estadístico, según el tipo de variable. Además, el documento metodológico no se alinea con los estándares de documentación de Interbank, por ejemplo, no tiene el logo, tipografía, colores corporativos, índice, control de versiones, anexos, bibliografía.	Revisar los hallazgos mencionados en las pruebas anteriores y alinear la documentación a los estándares de Interbank.	

RESULTADOS



Revisión documental



Réplica y Data Quality



Metodología



Performance

Réplica y Data Quality

Ámbito	Prueba	Resultado	Recomendación	Valoración
Data Quality	Exactitud BBDD	Los números de registros no están en el documento metodológico para cada muestra, sin embargo, se pueden inferir de los resúmenes estadísticos y los códigos enviados. En ese sentido, los tamaños de las muestras de entrenamiento y validación coinciden. El tamaño de la muestra de test (1,509,824 registros) no coincide con el documentado en el archivo de 01_resumen_estadistico.csv correspondiente a la muestra de test (1,338,493 registros). La diferencia de registros coincide con los registros del mes 202512 de test, por lo que se infiere que el análisis que se describe en este último archivo CSV no incluye este mes.	Estandarizar los análisis con el mismo periodo de evaluación. En el caso de que por razones operativas no se pueda, documentar los análisis que se haya realizado con periodos distintos.	

Réplica y Data Quality

Ámbito	Prueba	Resultado	Recomendación	Valoración
Data Quality	Unicidad BBDD	Se verifica que los registros de las muestras de validación y test son únicos a nivel de ID cliente y mes ('key_value', 'cod_mes'). Sin embargo, si se realiza el análisis a nivel de la variable cod_cli se encuentran duplicados, lo que parece indicar que el mismo cliente se puede repetir en un mes. Finalmente, no se tienen los ID de clientes para la muestra de train, por lo que no se puede validar la unicidad en esta muestra.	Aclarar si metodológicamente se pueden repetir los clientes en un mismo mes. Se deben incluir los id de los clientes en train para poder completar los análisis.	

Réplica y Data Quality

Ámbito	Prueba	Resultado	Recomendación	Valoración
Réplica	Construcción de la muestra	No fue posible replicar el proceso de construcción de la muestra, debido a que no se contó con los insumos necesarios para verificar los filtros aplicados durante su creación. En consecuencia, las bases de datos recibidas ya incorporaban dichos filtros, lo que constituye una limitación para el alcance del proceso de validación. Para la ejecución de las demás pruebas de réplica, se utilizó la muestra enviada.	Enviar los insumos para replicar la creación de la muestra.	
	Variable respuesta	No fue posible replicar el proceso de construcción de la variable respuesta, debido a que no se contó con los insumos necesarios para reproducir y validar su cálculo de manera independiente. En consecuencia, para las restantes pruebas de réplica, la variable respuesta fue considerada como un dato de entrada.	Enviar los insumos para replicar la variable respuesta.	

Réplica y Data Quality

Ámbito	Prueba	Resultado	Recomendación	Valoración
Réplica	Creación de variables	No se puede replicar el proceso de creación de variables, ya que no se dispone de los insumos necesarios.	Enviar los insumos para replicar la creación de variables.	
	Modelo	Debido a la utilización de entornos de desarrollo distintos, se observan ligeras diferencias en los resultados obtenidos durante el proceso de réplica del modelo. Se verifica que dichas diferencias no son materiales en el universo completo. Sin embargo, al aplicar el filtro de alertas automáticas sí se observan diferencias relevantes, como se detalla en la prueba "Indicadores de Eficiencia" en este mismo ámbito. Respecto al objeto del modelo entrenado, este no coincide con la documentación. Esto se debe probablemente a que el objeto y/o la documentación están desactualizados.	Se debe: - Resolver las diferencias en los resultados del segmento de alertas automáticas. - Verificar que la documentación del modelo coincida el objeto del modelo oficial que será utilizado en producción.	

Réplica y Data Quality – Modelo

Resumen réplica modelo

Aspecto	Modelo documentado	Réplica
Entrenamiento	XGBoost optimizado mediante SageMaker HPO	XGBoost entrenado localmente con los hiperparámetros documentados
Búsqueda de hiperparámetros	Ejecutada en AWS (SageMaker HPO)	No replicable por falta de acceso a AWS, se utilizaron los hiperparámetros finales documentados.
Variables del modelo	El modelo enviado por el cliente utiliza 29 variables, no corresponde al modelo final documentado.	Modelo construido con las 36 variables definidas en la documentación v2
Calibración	Platt Scaling + Temperature Scaling	Platt Scaling + Temperature Scaling replicados según notebook
Observaciones	El notebook y el modelo recuperado parecen corresponder a una versión anterior del desarrollo	La réplica se realizó siguiendo la documentación metodológica v2 y los hiperparámetros finales documentados

Métricas de performance

Conjunto de validación

Métrica	Documentado	Réplica
AUC	0,95786	0,9572
Gini	0,91572	0,9144

La réplica se considera adecuada, tomando en cuenta los insumos entregados por el cliente. Se logra reproducir la arquitectura, metodología de entrenamiento, estrategia de calibración e hiperparámetros documentados. Asimismo, el desempeño documentado en los conjuntos de validación y test sin aplicar filtros fue replicado sin diferencias significativas. Sin embargo, cómo se mostrará más adelante, hay diferencias significativas en dos meses al evaluar la muestra de test filtrando por alertas operativas.

Réplica y Data Quality

Ámbito	Prueba	Resultado	Recomendación	Valoración
Réplica	Importancia/Peso de las variables	Existen algunas diferencias mínimas en el orden de importancia de las variables debido a que el modelo replicado no es exactamente el mismo por la diferencia del entorno de desarrollo ejecutado. Sin embargo, las diferencias están dadas por valores mínimos y no se considera relevante.	No hay recomendación.	
	Indicadores de eficiencia	Se observan diferencias relevantes entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601 para el universo de alertas automáticas.	Analizar el motivo que explique las diferencias de AUC y Gini en los meses de 202512 y 202601 para el universo de alertas automáticas.	

Réplica y Data Quality – Importancia de variables

Feature	Documentado		Réplica		Diferencia	
	Avg abs SHAP	Importancia	Avg abs SHAP	Importancia	Avg abs SHAP	Importancia
cnt_trx_cargos_tot_3m	0.85922	15.6%	0.84954	15.2%	-0.00967	-0.4%
imp_trx_abonosefect_6m	0.60822	11.0%	0.58808	10.5%	-0.02014	-0.5%
pasivo_vs_ingresos	0.58852	10.7%	0.67529	12.1%	0.08677	1.4%
mto_pas_soles	0.44309	8.0%	0.51246	9.2%	0.06937	1.1%
imp_trx_cargosefe_6m	0.37405	6.8%	0.37427	6.7%	0.00021	-0.1%
cnt_alerta_hist	0.37253	6.8%	0.37628	6.7%	0.00375	0.0%
cnt_meses_singresos_12m	0.31193	5.7%	0.29579	5.3%	-0.01614	-0.4%
mto_del_ext_12m	0.23305	4.2%	0.28281	5.1%	0.04976	0.8%
num_antigüedad	0.21291	3.9%	0.22718	4.1%	0.01427	0.2%
cod_ubigeo_cd	0.21115	3.8%	0.19770	3.5%	-0.01345	-0.3%
ingresos_vs_facturacion	0.18356	3.3%	0.14319	2.6%	-0.04036	-0.8%
ratio_abonos_1m_vs_6m	0.15515	2.8%	0.16632	3.0%	0.01117	0.2%
rat_mntcrgsefetot_1m	0.13239	2.4%	0.11010	2.0%	-0.02229	-0.4%
cnt_trx_abonospromtot_3m	0.10781	2.0%	0.10552	1.9%	-0.00229	-0.1%
mto_fact_declarado_sunat	0.09937	1.8%	0.12236	2.2%	0.02299	0.4%
rat_trx_abonosefectot_9m	0.09010	1.6%	0.10465	1.9%	0.01455	0.2%
ratio_ingresos_exterior	0.08127	1.5%	0.05774	1.0%	-0.02353	-0.4%
ratio_cargos_1m_vs_6m	0.07488	1.4%	0.06169	1.1%	-0.01318	-0.3%
cod_sectorista_id	0.05305	1.0%	0.05407	1.0%	0.00102	0.0%
cnt_ros_hist	0.05092	0.9%	0.04941	0.9%	-0.00151	0.0%
rat_trx_abonosefectot_3m	0.04436	0.8%	0.01496	0.3%	-0.02939	-0.5%
ros_por_trx_3m	0.04147	0.8%	0.04676	0.8%	0.00530	0.1%
avg_trx_cargos_tot_3m	0.03424	0.6%	0.02934	0.5%	-0.00491	-0.1%
rat_trx_abonosefectot_1m	0.03165	0.6%	0.03957	0.7%	0.00792	0.1%
mto_al_ext_12m	0.01884	0.3%	0.01903	0.3%	0.00019	0.0%
max_mto_cpgrmen_12m	0.01853	0.3%	0.02370	0.4%	0.00518	0.1%
cnt_noticias	0.01728	0.3%	0.00794	0.1%	-0.00934	-0.2%
avg_cpmenegr_12m	0.01579	0.3%	0.02315	0.4%	0.00735	0.1%
fig_vrcn_abonos_5m_1m	0.01328	0.2%	0.00158	0.0%	-0.01170	-0.2%
ratio_egresos_exterior	0.01170	0.2%	0.00497	0.1%	-0.00673	-0.1%
share_cp_egresos	0.00831	0.2%	0.01089	0.2%	0.00257	0.0%
cnt_trx_sineny_alex_12m	0.00723	0.1%	0.00862	0.2%	0.00138	0.0%
fig_alerta_12m	0.00296	0.1%	0.00782	0.1%	0.00485	0.1%
avg_cp_men_ing_12m	0.00211	0.0%	0.00369	0.1%	0.00158	0.0%
share_cp_ingresos	0.00145	0.0%	0.00000	0.0%	-0.00145	0.0%
fig_vrcn_efc_cargos_5m_1m	0.00000	0.0%	0.00000	0.0%	0.00000	0.0%

Las variables *imp_trx_abonosefect_6m* (monto total de abonos en efectivo en los u6m) y *pasivo_vs_ingresos* (pasivo total en soles vs ingresos totales en los u6m), que corresponden a la segunda y tercera variable en orden de importancia de acuerdo con lo documentado, en la réplica pasan al tercer y segundo lugar, respectivamente.

Sin embargo, en general no se observan diferencias significativas de importancia de variables entre lo documentado y lo replicado.

Réplica y Data Quality – Indicadores de eficiencia

Universo total

Mes	Documentado		Réplica		Diferencia	
	AUC	Gini	AUC	Gini	AUC	Gini
202508	0.97	93.43	0.96	92.72	-0.01	-0.71
202509	0.94	87.81	0.95	90.82	0.01	3.01
202510	0.93	85.91	0.92	84.58	-0.01	-1.33
202511	0.94	88.76	0.94	88.95	0.00	0.19
202512	0.95	90.39	0.94	87.17	-0.01	-3.22
202601	0.97	94.50	0.97	93.53	0.00	-0.97
202602	0.96	91.83	0.96	92.23	0.00	0.40
202603	0.95	89.72	0.93	86.41	-0.02	-3.31
202604	0.98	95.91	0.98	95.06	0.00	-0.85

No se observan diferencias significativas entre lo documentado y la réplica.

Réplica y Data Quality – Indicadores de eficiencia

Universo solo alertas automáticas – Muestra de test

Métricas de desempeño

Mes	Documentado		Réplica		Diferencia	
	AUC	Gini	AUC	Gini	AUC	Gini
202508	0.71	42.02	0.73	45.51	0.02	3.49
202509	0.80	60.66	0.79	57.53	-0.01	-3.13
202510	0.82	64.70	0.83	65.92	0.01	1.22
202511	0.72	44.12	0.70	40.62	-0.02	-3.50
202512	0.76	52.90	0.93	85.87	0.17	32.97
202601	0.74	47.08	0.67	33.83	-0.07	-13.25
202602	0.78	55.44	0.81	62.45	0.03	7.01
202603	0.66	32.76	0.68	36.85	0.02	4.09
202604	0.73	46.40	0.74	48.46	0.01	2.06

Casos positivos con respecto al total

Mes	N° registros	positivos	% positivos
202508	194	34	17.53
202509	276	17	6.16
202510	269	28	10.41
202511	178	19	10.67
202512	278	2	0.72
202601	124	24	19.35
202602	526	13	2.47
202603	124	8	6.45
202604	296	110	37.16

Las métricas obtenidas sobre la muestra de alertas operativas presentan una mayor variabilidad respecto a la muestra de test completa, esto puede ocurrir por el reducido tamaño muestral y a la fluctuación mensual de la tasa de positivos. En particular, diciembre de 2025 registra únicamente 2 casos positivos sobre 278 observaciones, situación que genera una elevada sensibilidad de las métricas en la réplica. Adicionalmente, la diferencia entre las métricas documentadas y la réplica es considerable, por lo que se requiere una revisión de los datos de dicho mes.

RESULTADOS

-  Revisión documental
-  Réplica y Data Quality
-  Metodología
-  Performance

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Definición variable respuesta	La variable respuesta se define a partir de la clasificación realizada por los analistas, distinguiendo entre alertas catalogadas como “Con Riesgo” y “Falso Positivo”. En consecuencia, el modelo busca aproximar el criterio utilizado por los analistas PLAFT para evaluar las alertas generadas por los sistemas de monitoreo, actuando como un proxy del fenómeno de lavado de activos y financiamiento del terrorismo. Considerando que el desarrollo de modelos PLAFT se encuentra aún en una etapa relativamente incipiente, este enfoque se considera razonable. No obstante, debe tenerse presente que la clasificación de una misma alerta podría variar entre distintos analistas ante antecedentes similares, lo que introduce una fuente potencial de variabilidad en la variable objetivo. Este riesgo es inherente a los modelos basados en juicios expertos y constituye un desafío conocido en este ámbito (Berquist, 2024). Por otra parte, en la medida en que se disponga de información histórica suficiente y de una definición más directa del evento de interés, se recomienda evaluar el desarrollo de modelos orientados a explicar directamente el fenómeno PLAFT, reduciendo así la dependencia del criterio subjetivo de los analistas.	Se recomienda: - Indicar en la documentación cómo se mitigará el riesgo que la misma alerta sea calificada como positiva por un analista y negativa por otro analista. - Avanzar hacia un enfoque donde se modele directamente el fenómeno PLAFT.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Metodología de selección de muestra	Debido a la baja prevalencia de alertas con riesgo, se considera correcto usar todo el universo de casos positivos. Asimismo, se valora positivamente que la muestra esté compuesta de tres grupos: (1) alertas calificadas como con riesgo, (2) alertas calificadas como falsos positivos, (3) una muestra pequeña (0.5%) del universo de clientes sin alerta, pues mitiga parcialmente el sesgo de entrenar un modelo solo con los dos primeros grupos. Sin embargo, la proporción de clientes sin alerta elegida no está justificada y podría ser considerada como una decisión sin sustento metodológico. Cabe destacar que la conveniencia de induir clientes sin alerta depende directamente del objetivo del modelo. Si el propósito es identificar qué clientes deberían ser investigados por el sistema de monitoreo, la incorporación de clientes sin alerta resulta conceptualmente adecuada. En cambio, si el objetivo es evaluar la capacidad discriminatoria del sistema de alertas automáticas entre alertas con y sin riesgo, la inclusión de clientes sin alerta podría no ser consistente con la población objetivo del problema.	Probar distintas combinaciones de proporciones de clientes sin alerta dentro de la muestra de desarrollo, para identificar cuál de ellas entrega mejores métricas y de este modo justificar la elección de la proporción óptima usando un criterio cuantitativo más defendible.	
	Segmentación	No aplica, ya que se está trabajando en un subsegmento específico (BPE), más aun teniendo en cuenta la baja materialidad de casos positivos.	No hay recomendación.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Metodología selección de variables	El conjunto de variables seleccionadas para el modelo es adecuado, recogiendo información de distintos ámbitos, tales como: transaccionales, sociodemográficas, ratios financieros, comportamiento histórico AML, KYC, comercio exterior. Sin embargo, no hay una descripción detallada del proceso que permite reducir el conjunto original de 305 variables a las 36 finales. Como referencia, en el script <i>"0.limpieza_datos.ipynb"</i> se describe un proceso de selección de variables a partir de un conjunto inicial de 187 variables, usando los siguientes criterios: • Valores únicos (constantes). • % de valores nulos superior a un umbral determinado (20%). • Correlación de Pearson y Spearman superior a umbrales determinados (90% y 90%, respectivamente). Estos criterios se consideran adecuados, pero los umbrales usados deberían justificarse. Además, se evidencia que no es la versión final del script usado para seleccionar las variables del modelo, pues se obtienen 28 variables explicativas, mientras que el modelo validado tiene 36 en total. Por lo tanto, es necesario documentar cuál es la relación de esta versión del script con la selección de variables finales del modelo.	Se recomienda incluir en documento metodológico el proceso de selección descrito en el script <i>"0.limpieza_datos.ipynb"</i>, pero usando la versión final que permita llegar al universo de 36 variables del modelo validado. Asimismo, justificar los umbrales usados en los criterios de % de valores nulos y de correlaciones, y aclarar si los criterios y umbrales mencionados son los mismos que se usan para la selección final de variables.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Proceso de desarrollo de los modelos	El modelo desarrollado permite priorizar alertas generalizando el criterio usado por los analistas de investigación para identificar los casos con riesgo. Sin embargo, los siguientes hallazgos requieren atención inmediata: 1. No queda claro que las ventanas temporales del target y las variables explicativas sean disjuntas, si hay traslape temporal el modelo podría no ser aplicable porque "predice con el futuro". 2. No hay una separación explícita de clientes entre los conjuntos de train-test y validación. De hecho, se verifica que existen clientes presentes tanto en test como en validación. Debido a que la ventana temporal de entrenamiento más validación es relativamente corta (15 meses), existe un riesgo real de que las observaciones del mismo cliente en conjuntos distintos no sean independientes. 3. La calibración del modelo se hace sobre el mismo conjunto de validación, debería ser distinto.	Revisar las fuentes de datos de origen del modelo, para garantizar que las variables explicativas contienen información de períodos anteriores al de predicción. En el proceso de construcción de las muestras de train, test y validación, se recomienda asegurar que un mismo cliente no esté presente en más de uno de estos conjuntos. En caso de que existan clientes compartidos entre las muestras, se recomienda documentar y justificar dicha situación, evaluando su potencial impacto sobre los resultados del modelo. Usar un conjunto que sea independiente al de validación para calibrar el modelo.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Revisión de hiperparámetros seleccionados	El espacio de búsqueda usado para el desarrollo es adecuado. En particular, el hiperparámetro <code>scale_pos_weight=494</code> indica que los casos positivos son ponderados para balancear la muestra al momento de entrenar el modelo, aunque esta ya viene balanceada previamente. Además, no se usan parámetros de regularización como <code>lambda</code> y <code>alpha</code> , que permiten reducir el overfitting y obtener predicciones más estables.	Se recomienda complementar la documentación metodológica con una justificación del uso del hiperparámetro <code>scale_pos_weight</code> , considerando que previamente se realizó un proceso de balanceo de la muestra. Asimismo, se sugiere documentar los criterios que sustentan la decisión de no incorporar mecanismos de regularización durante el entrenamiento del modelo.	
	Metodología de performance	La metodología utilizada para medir el desempeño del modelo se considera adecuada, pero no suficiente. El uso de la precisión y el recall top K es necesario para medir cuál es el beneficio de la priorización de alertas. A diferencia de otros modelos predictivos con variable de respuesta binaria, las métricas habituales tales como el Gini o el KS no bastan por sí solas para medir el desempeño adecuadamente con la tipología del modelo validado.	Utilizar métricas complementarias para medir la eficiencia del modelo. Por ejemplo, se sugiere utilizar Lift para este tipo de problemas.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Auditoría de datos	Todas las observaciones o dudas fueron contestadas de manera oportuna por los dueños del modelo. No se encuentran observaciones relevantes en cuanto a las distribuciones de las variables del modelo.	No hay recomendación.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Metodología Empleada	Análisis de missing	Las variables categóricas fueron completadas con el valor "SIN_INFO", lo cual se considera adecuado. Sin embargo, las variables numéricas se rellenan con ceros, lo cual es inadecuado para variables de variaciones, ratios y antigüedad del cliente. En estos casos, las variables deben ser imputadas de acuerdo con el significado de la variable y del valor missing. Debido a que los conjuntos de datos vienen con las imputaciones ya aplicadas, no es posible cuantificar cuál es el impacto de esto.	Cuantificar en la etapa de preprocesamiento el % de missings, justo después de ejecutar la query de extracción de datos desde AWS Athena. En el caso de las variables numéricas, definir estrategias de imputación adecuadas, dependiendo del significado de la variable y del valor missing.	
	Importancia/Peso de las variables	Ninguna variable sobrepasa el umbral superior del 20% de importancia, definido en el Manual de Indicadores y Umbrales de Interbank. Sin embargo, hay cuatro variables por debajo del umbral inferior del 0.1% definido en el mismo manual (flg_alerta_12m, avg_cp_men_ing_12m, share_cp_ingresos, flg_vrcn_efe_cargos_5m_1m).	Considerar la eliminación desde las cuatro variables con menos de 0.1% de importancia.	

RESULTADOS

-  Revisión documental
-  Réplica y Data Quality
-  Metodología
-  Performance

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Bondad de ajuste	Indicadores de predicción/precisión	Para entrenar el modelo, la documentación indica que se usa como métrica de optimización el AUC, obteniendo como resultado 0.99040 en train y 0.95853 en validación dentro de la muestra, con una diferencia entre ambas equivalente a 6.4 puntos de Gini, lo cual indica que hay un ligero sobreajuste, pero que se considera aceptable debido a la baja materialidad de casos positivos. Se observa en el script de optimización de hiperparámetros con HPO que el AUC del score raw y calibrado en la muestra de validación es 0.9995, lo cual es consistente con la baja materialidad de positivos. No se reporta esta métrica sobre el universo de alertas automáticas, para poder tener una referencia del poder predictivo del modelo ante un escenario productivo, lo cual es una omisión relevante. Además, el AUC se considera una métrica inadecuada para definir si el modelo tiene buenos niveles de predicción en su entrenamiento. Para poder determinar esto, deberían incluirse métricas tales como precisión y recall top K, como se hizo en la muestra de test.	Incluir los resultados de precisión y recall top K en las muestras de train y validación, al momento de entrenar el modelo. Asimismo, las métricas deberían ser reportadas en el universo de alertas automáticas. Idealmente, en la optimización de hiperparámetros reemplazar el AUC como <i>eval_metric</i> por la precisión.	

Validación metodológica

Ámbito	Prueba	Resultado	Recomendación	Valoración
Bondad de ajuste	Resultados en validación	Los rangos de valores de precisión y recall top K, para distintos valores de K (=100, 200, 500, 1000, 2000) se consideran adecuados. En particular, la precisión top 100 varía entre 7% y 18%. Cabe señalar que, para efectos de seguimiento del modelo, la apertura por mes no es recomendable debido a la baja materialidad de casos positivos, que genera una alta volatilidad de las métricas en términos relativos.	Medir el desempeño del modelo a nivel más agregado (p. ej. trimestral), para que haya mayor materialidad de casos positivos.	



Limitaciones

Durante la validación se identificaron las siguientes limitaciones:

- No se contó con los insumos necesarios para validar los filtros aplicados en la construcción de la muestra de modelamiento (train + val + test).
- No se contó con los insumos necesarios para replicar la variable respuesta.
- No se contó con los insumos necesarios para replicar la creación de las variables explicativas del modelo.

La réplica de la construcción de la muestra, variable de respuesta y creación de variables explicativas se considera necesaria para tener una valoración completa del proceso de modelamiento y quedan como pendientes de revisión por el momento. Sin embargo, si no hay cambios al respecto y dada su relevancia dentro del proceso de validación, **en la versión final del informe estos puntos serán valorados como alertas.**



Conclusiones

Resumen



Revisión documental



Réplica y Data Quality



Metodología



Rendimiento



A continuación, se resumen los resultados obtenidos para las distintas pruebas de la validación:

Revisión Documental

La documentación metodológica permite comprender aspectos más relevantes del proceso de desarrollo del modelo (obtención base inicial, filtros aplicados, definición buenomalo, análisis temporal inicial, modelización, algoritmo utilizado, métricas y resultados). Sin embargo, no se alinea con los estándares de documentación de Interbank.

El objetivo del modelo, la definición de la población, la variable de respuesta y el uso previsto son coherentes con el desarrollo analítico. Sin embargo, la población objetivo presenta ambigüedad en su definición y falta incluir el tamaño de las muestras, junto con sus tasas de positivos. Asimismo, en el caso de la variable de respuesta es relevante especificar el significado del horizonte de evaluación de 30 días.

Los procesos de construcción, transformación, selección de variables y calibración del modelo no se encuentran suficientemente documentados, limitando trazabilidad y reproducibilidad del modelo. A su vez, la documentación de desempeño y validación debe fortalecerse, incorporando todas las métricas utilizadas y los resultados por muestra.

Replica y Data Quality

En general, se observa que los tamaños de muestra documentados coinciden con los replicados a partir de los datos recibidos. Sin embargo, debe detallarse con mayor precisión los conjuntos de datos utilizados en cada etapa del proceso de modelamiento. Respecto a la unicidad de los datos, se verifica que las bases no contienen duplicados.

La construcción de la muestra, la variable de respuesta y de las variables explicativas no pudo ser replicada, debido a que no se recibieron los insumos, así como tampoco la optimización de hiperparámetros, debido a que se hizo en AWS Sagemaker y para la réplica no se dispone de esta herramienta. Si bien hay una diferencia en los entornos de trabajo, sí se logró la réplica del modelo sin diferencias significativas, asumiendo los mismos hiperparámetros que los obtenidos por Interbank.

Un hallazgo crítico del proceso de validación es que el objeto del modelo entrenado no coincide con la documentación, lo que debe ser subsanado en futuras versiones del documento metodológico.

Otro hallazgo crítico es que, al aplicar el filtro de alertas automáticas y riesgo de cliente, que es el universo productivo, se observan diferencias significativas entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601, lo cual debe ser analizado en detalle.

A continuación, se resumen los resultados obtenidos para las distintas pruebas de la validación:

Revisión metodológica

El modelo validado incluye información desde múltiples fuentes, que se consideran relevantes para modelamiento y aportan un grado de riqueza adecuado para construir variables explicativas. Sin embargo, no hay trazabilidad completa del proceso de selección de variables creadas a partir de estas fuentes.

Respecto a la variable de respuesta, se considera relevante abordar el riesgo de que la misma alerta sea calificada como positiva por un analista y negativa por otro analista. Respecto a la selección de la muestra, se valora que se aproveche el universo completo de casos con alertas marcados como positivos. Asimismo, el balanceo de 0.5% de alertas positivas y 99.5% de alertas negativas se considera adecuado. Respecto a la conveniencia de incluir clientes sin alerta, esto depende directamente del objetivo del modelo. De todas maneras, se observa que la proporción de clientes sin alerta elegida (0.5%) no está justificada y podría ser considerada como una decisión sin sustento metodológico.

Respecto al proceso de desarrollo del modelo, se observan hallazgos críticos que deben ser analizados en detalle: (1) posible traslape temporal entre las variables explicativas y el target, (2) existencia de los mismos clientes en más de una muestra y (3) uso del conjunto de validación para calibrar el modelo.

Otro hallazgo crítico relacionado a metodología es que se observan variables numéricas que se rellenan con ceros de forma inadecuada desde el punto de vista técnico, tales como ratios, y el impacto de esto debe ser cuantificado.

Performance

El uso de Gini es inadecuado en el contexto del modelo validado, con poca materialidad de casos positivos. En su defecto, se recomienda el uso de precisión y recall top K, así como también el lift. En la misma línea, abrir el análisis por mes es desaconsejable, pues dificulta la evaluación del rendimiento del modelo. Teniendo en cuenta lo anterior, las métricas mensuales de Gini obtenidas en la muestra de test son consistentes con la métrica global observada en validación, difiriendo mensualmente en un máximo de 10% (esperable por la baja cantidad de casos positivos).

Un hallazgo importante asociado al performance es la disminución en el desempeño del modelo al filtrar las muestras por alertas operativas. Mientras que en la muestra de test completa se observan valores de Gini cercanos al 90%, en el subconjunto de alertas operativas el desempeño se reduce hasta niveles promedio cercanos al 50%. Esto resulta particularmente relevante, debido a que dicho subconjunto corresponde al universo objetivo sobre el cual se espera aplicar el modelo en producción.

Conclusión General

Tras el proceso de réplica y validación, se concluye que el modelo PLAFT Persona Jurídica Minorista presenta hallazgos metodológicos y limitaciones de replicabilidad que requieren análisis y revisión adicional. Entre los principales hallazgos se identifican diferencias relevantes entre el desempeño documentado y el replicado sobre el universo operativo de alertas, junto con una reducción significativa de la capacidad discriminadora del modelo al evaluarlo sobre la población objetivo de producción. En consecuencia, se recomienda profundizar el análisis de los hallazgos identificados y fortalecer la documentación metodológica antes de emitir una conclusión definitiva respecto de la idoneidad del modelo para su uso en producción.

Para cada una de las observaciones levantadas, se propone una recomendación (en verde):

Revisión Documental

Se levanta una **alerta media**:

- El documento metodológico no se alinea con los estándares de documentación de Interbank, por ejemplo, no tiene el logo, tipografía, colores corporativos, índice, control de versiones, anexos, bibliografía. **Para mitigar esta alerta, se recomienda alinear la documentación a los estándares de Interbank.**

Se levantan nueve **alertas bajas** (1/2):

- La población objetivo presenta ambigüedad en su definición. **Para mitigar esta alerta, se recomienda estandarizar la definición de la población objetivo en todo el documento para mayor coherencia.**
- Se define un horizonte de evaluación de 30 días, sin embargo, no se describe qué significa dicho horizonte. **Para mitigar esta alerta, se recomienda describir el significado del horizonte de evaluación para mayor claridad y entendimiento del problema.**

Revisión Documental

Se levantan nueve **alertas bajas** (2/2):

- No se cuenta con un diccionario de variables formal. **Para mitigar esta alerta, se recomienda elaborar un diccionario formal de variables.**
- El documento no detalla el tamaño de las muestras resultantes en cada etapa del proceso. Adicionalmente, se identifica una inconsistencia en la definición temporal de las muestras de desarrollo (train) y prueba (test). **Para mitigar esta alerta, se recomienda documentar el número de registros de cada muestra junto con su tasa de positivos y corregir el periodo de las muestras de desarrollo y test.**
- La población corresponde a un subsegmento específico (BPE, o Banca Pequeña Empresa). Esto no se encuentra descrito en el documento metodológico. **Para mitigar esta alerta, se recomienda mencionar en el documento metodológico que la población corresponde al subsegmento específico de BPE.**
- A nivel documental, no se dispone del detalle del proceso de creación y procesamiento de las variables. **Para mitigar esta alerta, se recomienda documentar el proceso de creación y procesamiento de las variables.**
- No se documenta el detalle de la exclusión de variables, los criterios aplicados y las variables descartadas en cada etapa del proceso. **Para mitigar esta alerta, se recomienda detallar el proceso de selección de variables.**
- Si bien se describe las ventajas de la calibración del modelo, no se detallan las técnicas utilizadas ni la muestra. Además, respecto al balanceo de clases, se omiten aspectos relevantes. **Para mitigar esta alerta, se recomienda detallar las técnicas utilizadas del proceso de calibración y la muestra utilizada y los tamaños de las clases antes y después del balanceo.**
- No aparecen en el documento las métricas relevantes para validar este tipo de modelos, tales como precisión y recall top K, que sí se incluyen en los scripts de desarrollo. **Para mitigar esta alerta, se recomienda incluir en el documento metodológico métricas de validación que se usan en el desarrollo, tales como precisión y recall top K.**

Réplica y Data Quality

Se levanta una **alerta alta y una media**:

- Se observan diferencias relevantes entre el AUC y Gini documentado y replicado, en particular en los meses de 202512 y 202601. **Para mitigar esta alerta, se recomienda analizar el motivo que explique las diferencias de AUC y Gini en los meses de 202512 y 202601.**
- Se recibe un objeto del modelo que no coincide con la documentación. **Para mitigar esta alerta, se recomienda verificar que la documentación del modelo coincida el objeto del modelo oficial que será utilizado en producción.**

Se levantan dos **alertas bajas**:

- El tamaño de la muestra de test no coincide con el documentado en el archivo de resumen estadístico. **Para mitigar esta alerta, se recomienda estandarizar los análisis con el mismo periodo de evaluación.**
- No se tienen los ID de clientes para la muestra de train, por lo que no se puede validar la unicidad en esta muestra. **Para mitigar esta alerta, se recomienda incluir los id de los clientes en train para poder completar los análisis.**

Revisión metodológica

Se levantan dos **alertas bajas** (1/2):

- La proporción de clientes sin alerta elegida no está justificada y podría ser considerada como una decisión sin sustento metodológico. **Para mitigar esta alerta, se recomienda probar distintas combinaciones de proporciones de clientes sin alerta dentro de la muestra de desarrollo, para identificar cuál de ellas entrega mejores métricas y de este modo justificar la elección de la proporción óptima usando un criterio cuantitativo más defendible.**

Revisión metodológica

Se levantan dos **alertas bajas** (2/2):

- No hay una descripción detallada del proceso que permite reducir el conjunto original de 305 variables a las 36 finales, ni tampoco una justificación del uso de los umbrales en los criterios de % de valores nulos y de correlaciones. Para mitigar esta alerta, se recomienda incluir en documento metodológico el proceso de selección descrito en el script “0.limpieza_datos.ipynb”, pero usando la versión final que permita llegar al universo de 36 variables del modelo validado a partir de las 305 variables iniciales de acuerdo con el documento, y justificar los umbrales usados en los criterios de % de valores nulos y de correlaciones (20% y 90%, respectivamente), así como también aclarar si los criterios y umbrales mencionados son los mismos que se usan para la selección final de variables.

Se levantan dos **alertas medias**:

- Respecto al proceso de desarrollo del modelo, (1) no queda claro que las ventanas temporales del target y las variables explicativas sean disjuntas, (2) no hay una separación explícita de clientes entre los conjuntos de train-test y validación, y (3) la calibración del modelo se hace sobre el mismo conjunto de validación. Para mitigar esta alerta, se recomienda (1) revisar las fuentes de datos de origen del modelo, para garantizar que las variables explicativas contienen información de períodos anteriores al de predicción, (2) en la construcción de las muestras de train, test y validación, garantizar que un cliente pueda aparecer en exactamente una de las tres, para garantizar la independencia del conjunto de validación, y (3) usar un conjunto que sea independiente al de validación para calibrar el modelo.
- Las variables numéricas se rellenan con ceros, lo cual es inadecuado para variables de variaciones, ratios y antigüedad del cliente. Para mitigar esta alerta, se recomienda usar estrategias de imputación adecuadas, dependiendo del significado de la variable y del valor missing.

Performance

Se levanta una **alerta baja**:

- El AUC se considera una métrica inadecuada para definir si el modelo tiene buenos niveles de predicción en su entrenamiento. Para mitigar esta alerta, se recomienda incluir los resultados de precisión y recall top K en las muestras de train y validación, al momento de entrenar el modelo. Asimismo, las métricas deberían ser reportadas en el universo de alertas automáticas.

The logo for ubimia, featuring the word "ubimia" in a white, lowercase, sans-serif font. The letter "u" is stylized with a small hook. A registered trademark symbol (®) is located at the top right of the letter "a". The logo is centered on a dark blue background with a large, curved, teal-colored shape on the right side.

ubimia®